

Politechnika Warszawska

W Y D Z I A Ł E L E K T R Y C Z N Y



Instytut Sterowania i Elektroniki Przemysłowej

Praca dyplomowa magisterska

na kierunku Informatyka Stosowana

w specjalności Inżynieria Danych i Multimedia

Badanie metod wyjaśnialności sztucznej inteligencji na przykładzie analizy istotności cech

Daniel Ślusarczyk

numer albumu 311511

promotor

dr inż. Grzegorz Sarwas

WARSZAWA 2025

Badanie metod wyjaśnialności sztucznej inteligencji na przykładzie analizy istotności cech

Streszczenie

Dynamiczny rozwój sztucznej inteligencji obserwowany w ostatnich latach oraz rosnąca złożoność współczesnych modeli uczenia maszynowego doprowadziły do istotnego wyzwania w obszarze rozumienia dokładnego sposobu generowania wyników z ich pomocą. Wiele kluczowych decyzji w sektorach o wysokim ryzyku (medycyna, transport, administracja) jest podejmowanych przez systemy, których dokładne działanie jest niezrozumiałe nawet dla osób dysponujących wiedzą ekspercką. Takie modele, określane mianem tzw. *czarnych skrzynek*, stanowią rozwiązania, których wewnętrzna logika jest zbyt zaawansowana zarówno dla użytkowników końcowych, jak i projektantów algorytmów do bezpośredniego opisanie skutków uzyskiwanych wyników. Taka okoliczność, w kontekście rosnących wymagań etycznych i regulacyjnych (np. prawa do wyjaśnienia decyzji), doprowadziła do powstania dziedziny wyjaśnialnej sztucznej inteligencji (XAI), której celem jest zwiększenie możliwości interpretacyjnych modeli. Nowo powstała gałąź sztucznej inteligencji stanowi zarówno filozofię projektowania przejrzystszych rozwiązań uczenia maszynowego, jak i dostarcza gotowych rozwiązań wykorzystujących złożoną strukturę popularnych algorytmów do opisu ich właściwości, w tym ważności cech wpływających na generowane predykcje.

Przedmiotem niniejszej pracy jest empiryczna ocena trzech popularnych technik wyjaśnialnej sztucznej inteligencji (LIME, PFI, SHAP) w badaniu różnych modeli uczenia maszynowego, obejmujących regresję liniową, drzewa decyzyjne, lasy losowe, XGBoost oraz perceptrony wielowarstwowe. W ramach części projektowej opracowano środowisko eksperymentalne, które miało za zadanie porównanie jakości, stabilności i zgodności wyników ważności cech w obrębie wariantów testowych. Uzyskane rezultaty wskazały, że wszystkie techniki mają zbliżony potencjał w identyfikacji najważniejszych predyktorów, lecz znacząco różnią się szczegółowym rozkładem ważności pozostałych cech. Największą stabilność uzyskano dla metod PFI i SHAP, natomiast LIME w wariancie globalnym wykazała się ograniczoną zasadnością stosowania. Praca podkreśla również wpływ współliniowości cech na interpretowalność modeli przy zastosowaniu wymienionych technik i wskazuje ich ograniczenia w tym zakresie. Zwieńczeniem pracy jest ocena praktycznej użyteczności omawianych metod oraz wskazanie dalszych kierunków badań.

Słowa kluczowe: wyjaśnialna sztuczna inteligencja, ważność cech, techniki XAI, SHAP, LIME, PFI

Study of artificial intelligence explainability methods using feature importance analysis

Abstract

The dynamic development of artificial intelligence observed in recent years, along with the growing complexity of modern machine learning models, has led to a significant challenge in understanding the exact way in which their outputs are generated. Many key decisions in high-risk sectors (medicine, transport, public administration) are made by systems whose exact operation is incomprehensible even to individuals with expert knowledge. Such models, referred to as *black boxes*, constitute solutions whose internal logic is too advanced both for end users and for algorithm designers to directly describe the causes of the obtained outputs. This situation, in the context of growing ethical and regulatory requirements (e.g., the right to explanation), has resulted in the emergence of the field of explainable artificial intelligence (XAI), whose aim is to enhance the interpretability of models. The newly established branch of artificial intelligence represents both a philosophy of designing more transparent machine learning solutions and a set of ready-made methods that leverage the intricate structure of popular algorithms to describe their properties, including the feature importance of generated predictions.

The subject of this thesis is the empirical evaluation of three popular explainable artificial intelligence techniques (LIME, PFI, SHAP) in the study of various machine learning models, including linear regression, decision trees, random forests, XGBoost, and multilayer perceptrons. As part of the project component, a experimental environment was developed to compare the quality, stability, and consistency of feature-importance results across test variants. The obtained results indicate that all techniques have a similar potential in identifying the most important predictors, yet they differ significantly in the detailed distribution of importance across the remaining features. The highest stability was achieved for the PFI and SHAP methods, whereas LIME in its global variant demonstrated limited justification for practical use. The thesis also highlights the impact of feature collinearity on the interpretability of models when applying the aforementioned techniques and identifies their limitations in this regard. The work concludes with an assessment of the practical usefulness of the discussed methods and an indication of future research directions.

Keywords: explainable artificial intelligence, feature importance, XAI techniques, SHAP, LIME, PFI

Spis treści

1	Wstęp	9
2	Wprowadzenie teoretyczne	13
2.1	Wyjaśnialna sztuczna inteligencja	13
2.2	Klasyfikacja metod XAI	16
2.3	Analiza istotności cech	19
2.3.1	LIME	19
2.3.2	SHAP	22
2.3.3	PFI	24
3	Dane	27
3.1	Zbiór 1: Life Expectancy (WHO)	28
3.2	Zbiór 2: Hospital Length of Stay (Microsoft)	30
4	Prace eksperymentalne	33
4.1	Metodologia	33
4.2	Implementacja	34
4.3	Sieci neuronowe	38
4.3.1	Skuteczność modeli	38
4.3.2	Techniki XAI	40
4.4	Klasyczne modele	56
4.4.1	Skuteczność modeli	56
4.4.2	Techniki XAI	58
4.5	Wnioski	71
5	Podsumowanie	73
	Bibliografia	75
	Wykaz skrótów i symboli	77
	Spis rysunków	79
	Spis tabel	81

Rozdział 1

Wstęp

W ostatnich latach sztuczna inteligencja (ang. *artificial intelligence*, SI) stała się jednym z kluczowych czynników kształtujących rzeczywistość na całym świecie. Jej gwałtowny wzrost zastosowań wynika z połączenia kilku czynników: zwiększonej dostępności danych, rozwoju infrastruktury obliczeniowej oraz postępów w metodach uczenia maszynowego (ang. *machine learning*, UM). Przyjęcie technologii SI w różnych sektorach, takich jak opieka zdrowotna, finanse, czy administracja, nastąpiło w niespotykane szybkie tempo. SI umożliwia bowiem automatyzację złożonych zadań, analizę ogromnych wolumenów danych oraz identyfikację wzorców trudnych do uchwycenia dla człowieka, co w konsekwencji czyni ją nieodzownym elementem współczesnych procesów decyzyjnych [28]. Ponadto na przestrzeni ostatnich lat szczególnie dynamiczny rozwój obserwuje się w zakresie zastosowań biznesowych. Zgodnie z raportem *Artificial Intelligence Index Report 2025*, opracowanym przez Stanford University, w 2024 roku aż 78% organizacji deklaruowało wykorzystanie systemów sztucznej inteligencji w co najmniej jednej funkcji biznesowej. Stanowi to istotny wzrost w porównaniu z 55% w roku 2023. Jeszcze bardziej znaczący przyrost dotyczył wykorzystania generatywnej sztucznej inteligencji (*GenAI*), której udział zwiększył się z 33% w 2023 roku do 71% w roku 2024 [22]. Szczegółowy przebieg tego procesu uwidacznia rys. 1.

Ten sam raport sygnalizuje, że rozwój technologii SI znajduje także odzwierciedlenie w działalności naukowej. Zgodnie z wykresem przedstawionym na rys. 2 liczba publikacji naukowych z obszaru informatyki, dotyczących zagadnień sztucznej inteligencji, wzrosła ponad dwukrotnie w latach 2013–2023 z około 102 tys. do ponad 242 tys. artykułów. Tylko w roku 2023 liczba ta zwiększyła się o 19,7%, co potwierdza nie tylko naukowy, lecz także interdyscyplinarny charakter SI, który obejmuje obecnie dziedziny od inżynierii oprogramowania po interakcję człowiek–komputer [22].

Mimo licznych sukcesów i powszechnego zastosowania, rozwój SI przyniósł również szereg wyzwań natury technicznej, etycznej i prawnej. Jednym z najpoważniejszych problemów stała się trudność w interpretacji i wyjaśnianiu działania modeli, zwłaszcza tych o dużej złożoności, których przykładami są: modele zespołowe, sieci neuronowe czy duże modele językowe. Wysoka dokładność predykcyjna tych modeli często osiągnięta jest kosztem ich transparentności, co doprowadziło do określania ich mianem *czarnej skrzynki* (ang. *black box*) [15, 22, 28]. Zgodnie z literaturą, złożoność współczesnych

Share of respondents who say their organization uses AI in at least one function, 2017–24

Source: McKinsey & Company Survey, 2024 | Chart: 2025 AI Index report




Figure 4.4.1

Rysunek 1. Wykorzystanie SI w funkcjach biznesowych w latach 2017–2024, źródło: [22]

Number of AI publications in CS worldwide, 2013–23

Source: AI Index, 2025 | Chart: 2025 AI Index report




Figure 1.1.1

Rysunek 2. Liczba publikacji o SI w dziedzinie informatyki na świecie w latach 2013–2023, źródło: [22]

modeli powoduje, że nawet wiedza ekspercka jest niewystarczająca do ich interpretacji [28]. Tworzy to konieczność szukania kompromisu między dokładnością a interpretowalnością [22], a samo zjawisko ma znaczące konsekwencje praktyczne, ponieważ modele typu *czarna skrzynka* mogą podejmować decyzje o istotnych skutkach dla osób indywidualnych, przedsiębiorstw, a nawet społeczeństw. Tym samym pozostają przy tym nieprzejrzyste dla końcowych użytkowników i twórców

takich rozwiązań [15]. Brak zrozumienia logiki działania takich systemów utrudnia identyfikację błędów, uprzedzeń lub tzw. *halucynacji*, prowadząc do podejmowania decyzji nieuzasadnionych lub potencjalnie szkodliwych [15]. W literaturze odnotowano przypadki, w których brak przejrzystości systemów SI skutkowało poważnymi konsekwencjami społecznymi, takimi jak niesłuszne wyroki sądowe, błędne diagnozy medyczne czy dyskryminujące decyzje rekrutacyjne [17, 26]. Efekt *czarnej skrzynki* może prowadzić zarówno do nadmiernego zaufania wobec modeli, których decyzji nie można zweryfikować lub do całkowitej utraty zaufania wobec technologii, co ogranicza jej wdrażanie w sektorach, w których jest szczególnie istotna [15, 20, 28].

W kontekście opisanych zagrożeń coraz większe znaczenie zyskuje wymóg przejrzystości i odpowiedzialności. Postulaty te mają nie tylko charakter etyczny, lecz także prawny. Przejrzystość przetwarzania danych stanowi bowiem podstawową zasadę ochrony danych osobowych, co zostało zapisane m.in. w ogólnym rozporządzeniu o ochronie danych (ang. *General Data Protection Regulation*, RODO) przyjętym przez Unię Europejską w 2018 roku [25, 28]. RODO przewiduje tzw. prawo do wyjaśnienia (ang. *right to explanation*), zgodnie z którym każda osoba ma prawo do uzyskania znaczących informacji o logice leżącej u podstaw automatycznego podejmowania decyzji [9]. W konsekwencji, zagadnienie wyjaśnialności przestało być wyłącznie zagadnieniem teoretycznym, a stało się realnym wymogiem regulowanym prawnie. Istotne jest również, że na poziomie globalnym problem przejrzystości i odpowiedzialności w zakresie sztucznej inteligencji znalazł odzwierciedlenie w inicjatywach międzynarodowych organizacji, takich jak OECD, ONZ czy Unia Afrykańska. W 2024 roku opublikowano ramy etyczne i prawne dotyczące odpowiedzialnej SI, podkreślające znaczenie wyjaśnialności, wiarygodności i bezpieczeństwa systemów opartych na sztucznej inteligencji [9, 22]. Zgodnie z tymi zasadami, niedopuszczalne jest stosowanie modeli, które ukrywają logikę podejmowania decyzji, gdyż ogranicza to odpowiedzialność oraz możliwość audytu decyzji generowanych przez takie rozwiązania [28].

W odpowiedzi na te wyzwania wykształciła się nowa dziedzina badań – wyjaśnialna sztuczna inteligencja (ang. *explainable artificial intelligence*, XAI). Jej celem jest opracowanie metod i narzędzi umożliwiających interpretację wyników modeli SI oraz dostarczanie użytkownikom zrozumiałych wyjaśnień decyzji podejmowanych przez systemy. XAI koncentruje się na uczynieniu zachowania modeli bardziej transparentnym poprzez identyfikację czynników wpływających na decyzje predykcyjne, ale stanowi również całą filozofię projektowania algorytmów z zachowaniem dostępu do danych umożliwiających, przynajmniej częściowej, zrozumienie przyczyn stojących za wygenerowanymi wynikami. Właściwie zaprojektowane mechanizmy XAI mogą wspierać proces audytu modeli, zwiększać zaufanie społeczne do technologii oraz umożliwiać kontrolę zgodności z przepisami [28]. Dynamiczny rozwój tej gałęzi od samego momentu powstania wskazuje na rosnące znaczenie wyjaśnialności w nowoczesnych systemach SI.

Celem pracy jest zbadanie skuteczności, stabilności oraz wiarygodności wybranych technik wyjaśnialności w kontekście różnych typów modeli uczenia maszynowego, takich jak: lasy losowe, drzewa decyzyjne, modele składane (XGBoost), perceptrony wielowarstwowe i regresja liniowa. Analiza obejmie porównanie wyników metod LIME, SHAP i PFI w kontekście interpretacji decyzji

modeli oraz oceny ich zdolności do odwzorowania faktycznych zależności pomiędzy cechami a wynikami modelu. Wybór tych rozwiązań jest podyktowany możliwością ich bezpośredniego porównania ze względu na podobieństwo generowanych wyników oraz popularność ich zastosowań potwierdzoną w wielu artykułach naukowych.

Niemniej sama praca, podzielona na pięć rozdziałów, stanowi próbę pogłębienia obszaru XAI poprzez empiryczną analizę metod interpretacji modeli oraz ocenę ich przydatności w kontekście praktycznym i teoretycznym. Całość rozważań wprowadza opis tematyki w formie niniejszego wstępu 1, rozszerzony w kolejnym rozdziale 2 o najważniejsze pojęcia konieczne do kompleksowego zrozumienia problematyki i ujednolicenia sposobu rozumienia używanych terminów. Następujący po nim rozdział 3 został poświęcony dokładnemu przedstawieniu analizowanych danych i najważniejszych zależności, które w nich występują. Natomiast sekcja 4 koncentruje się na omówieniu całego procesu przeprowadzonych eksperymentów i została zwieńczona podsumowaniem 5 całości rozważań w formie zakończenia pracy.

Rozdział 2

Wprowadzenie teoretyczne

Niniejszy rozdział skupia się na teoretycznym przedstawieniu istotnych koncepcji dla prawidłowego rozumienia omawianych zagadnień w dalszej części pracy. Rozpoczyna się kompletnym wprowadzeniem terminu *wyjaśnialnej sztucznej inteligencji* oraz zagadnień powiązanych, a następnie przechodzi do teoretycznego opisu technik będących obiektem dalszych badań. Wybrane pojęcia mają kluczowe znaczenie dla opisywanych rozważań i ujednolicenia sposobu rozumienia problemu.

2.1 Wyjaśnialna sztuczna inteligencja

Jak wspomniano we wstępie (1), sztuczna inteligencja stanowi obecnie jedno z kluczowych pól rozwoju technologicznego, determinując kierunek transformacji wielu gałęzi gospodarki. Współczesne systemy wykazują zdolność do automatycznego uczenia się wzorców z danych, przewidywania złożonych zjawisk oraz wspomagania procesów decyzyjnych w takich dziedzinach jak medycyna, finanse czy prawo. Wraz ze wzrostem ich zastosowań pojawia się jednak zasadniczy problem z ograniczoną przejrzystością mechanizmów decyzyjnych. Modele te często określa się mianem tzw. *czarnych skrzynek*, ponieważ sposób generowania predykcji pozostaje niejasny nawet dla ich twórców [28]. Taka charakterystyka modeli UM prowadzi do licznych wyzwań etycznych, prawnych i społecznych. Dodatkowo, ukryte błędy, niewystarczająca transparentność oraz brak możliwości przypisania odpowiedzialności za decyzje stanowią podstawę do wykluczenia takich rozwiązań. Jak wskazuje powiązana z tematem literatura, konsekwencje stosowania nieprzejrzystych modeli obejmują błędne decyzje w obszarach o wysokiej stawce, takich jak orzeczenia sądowe, medycyna czy analiza środowiskowa [26]. W świetle tych problemów urzeczywistniła się potrzeba opracowania nowej dziedziny badań – *wyjaśnialnej sztucznej inteligencji* (ang. *explainable artificial intelligence*, XAI), której celem jest zwiększenie transparentności procesów decyzyjnych modeli przy zachowaniu ich wysokiej skuteczności [5].

Definicja

Wyjaśnialna sztuczna inteligencja obejmuje metody i narzędzia, które umożliwiają zrozumienie oraz interpretację wyników generowanych przez systemy SI. Jak wskazuje [5], głównym celem XAI jest tworzenie modeli zdolnych do *samowyjaśniania się* lub opracowanie technik pozwalających na analizę decyzji już wytrenowanych modeli. Oznacza to, że XAI łączy dwa uzupełniające się podejścia:

1. projektowanie modeli interpretowalnych, które są zrozumiałe z natury,
2. stosowanie technik wyjaśniania *post-hoc*, które analizują działanie modeli o złożonej strukturze, takich jak głębokie sieci neuronowe.

Podczas gdy pierwsze podejście może być rozumiane jako cała filozofia towarzysząca tworzeniu modeli, drugie stanowi zestaw narzędzi dla modeli o strukturze uniemożliwiającej zastosowanie takiego paradygmatu. Warto również podkreślić, że dynamiczny rozwój tej dziedziny nastąpił dopiero po roku 2017, kiedy to wzrosło zainteresowanie publikacjami dotyczącymi technik wyjaśniania modeli [5]. XAI stało się kluczowym elementem nie tylko badań akademickich, ale również regulacji prawnych – zwłaszcza w kontekście przepisów dotyczących ochrony danych osobowych oraz odpowiedzialności za decyzje.

Terminologia

W literaturze przedmiotu istnieje znaczna niejednoznaczność w stosowaniu terminów opisujących przejrzystość modeli sztucznej inteligencji. Pojęcia takie jak *interpretowalność* i *wyjaśnialność* często używane są zamiennie, mimo że odnoszą się do odmiennych aspektów modelu [7]. Zgodnie z klasyfikacją przedstawioną w [21], uzupełnieniem są również terminy: *rozumiałość*, *pojmovalność* oraz *transparentność*, które precyzują różne perspektywy postrzegania modeli, a w języku poza dziedzinyowym postrzegane są synonimicznie. Poniżej zostały wprowadzone wspomniane pojęcia w celu unormowania ich rozumienia.

- Interpretowalność (ang. *interpretability*) odnosi się do zdolności modelu do przedstawiania swoich decyzji w sposób zrozumiały dla człowieka. Jest to cecha wynikająca z samej konstrukcji modelu, umożliwiająca obserwatorowi prześledzenie zależności między danymi wejściowymi a wynikiem. Modele o wysokiej interpretowalności takie jak regresja liniowa czy drzewa decyzyjne, pozwalają na bezpośrednią analizę ich struktury bez potrzeby stosowania dodatkowych technik wyjaśniających [7].
- Wyjaśnialność (ang. *explainability*) oznacza zdolność modelu lub zewnętrznego mechanizmu do generowania uzasadnień decyzji podejmowanych przez system. Obejmuje procedury mające na celu przybliżenie użytkownikowi sposobu działania modelu, zwłaszcza w przypadku złożonych algorytmów [21].

Oprócz tych dwóch kluczowych terminów, w literaturze z zakresu wyjaśnialnej sztucznej inteligencji (XAI) coraz częściej pojawiają się dodatkowe pojęcia:


- Zrozumiałość (ang. *understandability*) określa stopień, w jakim człowiek potrafi pojąć sposób działania modelu (logikę i funkcje) bez konieczności znajomości jego wewnętrznej struktury lub algorytmicznych mechanizmów przetwarzania danych [21]. Zrozumiałość ma charakter dwustronny: odnosi się zarówno do zdolności modelu do bycia zrozumiałym, ale również zdolności człowieka do zrozumienia przedstawionych wyjaśnień. Tym samym jest to pojęcie nadrzędne wobec *interpretowalności* i *wyjaśnialności* stanowiąc fundament koncepcji XAI.
- Pojmowalność (ang. *comprehensibility*) oznacza zdolność modelu do przedstawiania wiedzy w sposób zrozumiały dla człowieka. Zgodnie z definicją wprowadzoną przez Michalskiego [19], wyniki uczenia powinny mieć postać symbolicznych opisów, semantycznie i strukturalnie podobnych do tych, jakie tworzyłby ekspert ludzki, czyli *porcji* informacji możliwych do interpretacji w języku naturalnym. Niemniej jednak, we współczesnej interpretacji [11] pojęcie to jest często używane zamiennie z *interpretowalnością* i odnosi się do stopnia, w jakim człowiek potrafi zrozumieć logikę działania modelu – im prostsza jego struktura, tym wyższy poziom pojmowalności.
- Transparentność (ang. *transparency*) oznacza sytuację, w której model jest sam w sobie zrozumiały i nie wymaga dodatkowych technik wyjaśniających. Transparentne modele są zazwyczaj interpretowalne z natury i pozwalają na bezpośrednią analizę logicznych reguł lub zależności matematycznych. W niniejszej pracy pojęcie to jest bardzo zbliżone znaczeniowo z *interpretowalnością*.

Podsumowując, termin *zrozumiałość* stanowi pojęcie nadrzędne, łączące w sobie wszystkie wymienione aspekty. W praktyce systemy wyjaśnialnej sztucznej inteligencji powinny zatem uwzględniać nie tylko przejrzystość struktury modelu, ale także zdolność użytkowników do efektywnej analizy dostarczonych wyjaśnień, co podkreśla semantyka wprowadzonych pojęć.

Kompromis interpretowalności i dokładności

Jednym z centralnych zagadnień w dyskusji o XAI jest kompromis pomiędzy interpretowalnością i dokładnością modelu. Modele interpretowalne umożliwiają z założenia śledzenie procesu decyzyjnego, jednak ich skuteczność w zadaniach o wysokiej złożoności może nie być satysfakcjonująca. Z kolei modele nieprzejrzyste, takie jak głębokie sieci neuronowe, oferują wysoką dokładność predykcji kosztem utraty przejrzystości [7, 30]. Kompromis ten został przedstawiony na opracowanym rys. 3. Na jednym krańcu spektrum znajdują się modele interpretowalne, na drugim złożone architektury wymagające zastosowania metod XAI. Ponadto rysunek nakreśla koncepcję, że model może być zrozumiały w różnym stopniu zależnie od zastosowanych parametrów i architektury. Wskazuje to, że przejrzystość i dokładność nie stanowią dwóch dyskretnych kategorii, lecz są raczej pewnym możliwym do uzyskania spektrum. Rysunek przedstawia także tzw. *szarą strefę*, w której modele

pośrednie (np. warianty lasu losowego) zachowują pewien poziom interpretowalności, utrudniając jednoznaczną klasyfikację.



Rysunek 3. Spektrum przejrzystości modeli uczenia maszynowego, źródło: opracowanie własne

2.2 Klasyfikacja metod XAI

Klasyfikacja technik wyjaśnialnej sztucznej inteligencji jest zadaniem nietrywialnym ze względu na ciągły rozwój tej dziedziny i czas niezbędny do ugruntowania wielu pojęć. Najczęściej spotykany podział odbywa się ze szczególnym uwzględnieniem rozróżnienia na techniki *post-hoc* oraz projektowanie *modeli transparentnych*. W literaturze podkreśla się również dynamiczny charakter tej dziedziny, czego konsekwencją jest współistnienie wielu niejednoznacznych taksonomii [11, 18]. Jednakże najczęściej spotykany w literaturze podział, omawiany uprzednio przy wprowadzaniu definicji XAI, jest zorientowany na pochodzenie wyjaśnień i wyróżnia dwie podstawowe strategie:

1. wyjaśnialność *post-hoc* – polegającą na rekonstruowaniu wyjaśnień dla już wytrenowanego modelu,
2. projektowanie modeli transparentnych (podejście *ante-hoc*) – zakładające konstruowanie modeli z wbudowaną interpretowalnością [5, 23].

Niektóre prace rozszerzają ten podział, wskazując ponadto na istnienie trzeciego rodzaju podejścia zwanego *Real-time XAI*, w którym wyjaśnienia generowane są równocześnie z procesem podejmowania decyzji przez model. Takie rozwiązania są charakterystyczne dla środowisk wymagających natychmiastowej przejrzystości, np. w systemach autonomicznych czy krytycznych aplikacjach decyzyjnych [2, 23]. Oprócz przedstawionej klasyfikacji, często podstawowe podziały odbywają się również ze względu na: typy rozwiązywanych problemów, zakres wspieranych modeli, dane wejściowe oraz dane wyjściowe [29].

Wyjaśnialność post-hoc

To podejście do wyjaśnialności odnosi się do metod opracowanych w celu zwiększenia interpretowalności modeli, które nie są transparentne z założenia. Ich wewnętrzna struktura i sposób podejmowania decyzji są niedostępne lub zbyt złożone, aby można je było zrozumieć bezpośrednio. Przykładem takich modeli są głębokie sieci neuronowe (ang. *deep neural networks*, DNN) czy zespoły drzew decyzyjnych (ang. *ensemble methods*) [11, 29]. Celem omawianych metod jest odtworzenie lub przynajmniej przybliżenie logiki decyzyjnej takiego modelu. Dzieje się to poprzez dostarczanie zrozumiałych dla człowieka informacji o tym, jak dane wejściowe wpływają na uzyskane przewidywania. W przeciwieństwie do podejścia projektowania modeli transparentnych, techniki post-hoc nie ingerują w strukturę modelu, a raczej stanowią warstwę interpretacyjną dobudowaną po jego wytrenowaniu. Literatura wskazuje, że metody post-hoc rozwiązują trzy główne klasy problemów opisane poniżej [5].

1. Wyjaśnienie modelu czarnej skrzynki – polega na budowie globalnego, uproszczonego modelu, który naśladuje zachowanie czarnej skrzynki, umożliwiając zrozumienie jej ogólnej logiki działania.
2. Wyjaśnienie wyniku czarnej skrzynki – odnosi się do dostarczania lokalnego wyjaśnienia dotyczącego konkretnej predykcji, tj. wskazania, dlaczego model przypisał danej instancji określoną etykietę.
3. Inspekcja czarnej skrzynki – obejmuje analizę wizualną lub tekstową, której celem jest zrozumienie struktury i funkcjonowania modelu, np. poprzez wykresy albo mapy istotności.

Metody wyjaśniania post-hoc obejmują również różnorodne formy prezentacji wyjaśnienia. Do najczęściej wyróżnianych kategorii należą [5]:

1. Wyjaśnienia tekstowe (ang. *text explanations*) – celem wyjaśnień tekstowych jest przedstawienie decyzji modelu w postaci reguł logicznych lub semantycznych. Wyjaśnienia te często przybierają formę symbolicznych reguł *if-then*, które opisują, jakie warunki wejściowe prowadzą do określonego wyniku. W kontekście przetwarzania języka naturalnego stosuje się także tzw. *rationale-based explanations*, polegające na wskazaniu fragmentów tekstu kluczowych dla decyzji modelu. Tego typu wyjaśnienia powinny być intuicyjne i zrozumiałe dla użytkownika końcowego.
2. Wyjaśnienia wizualne (ang. *visual explanations*) – opierają się na wizualizacji zachowania modelu. W przypadku analizy obrazów wykorzystywane są m.in. *maski istotności*, które podświetlają obszary mające największy wpływ na decyzję modelu. W przypadku danych tablicowych i liczbowych stosuje się narzędzia takie jak *wykresy zależności częściowej* czy *wykresy oczekiwanych wartości warunkowych*, pozwalające analizować relacje pomiędzy zmiennymi a wynikiem modelu.

3. Wyjaśnienia lokalne (ang. *local explanations*) – skupiają się na analizie pojedynczych obserwacji i ich najbliższego otoczenia w przestrzeni danych. Idea polega na tym, że zachowanie nawet bardzo złożonego modelu można w przybliżeniu opisać lokalnie za pomocą prostszego, interpretowalnego modelu (np. modelu liniowego). Najbardziej znaną metodą tego typu jest LIME, w której lokalna aproksymacja opiera się na perturbacjach wejść w otoczeniu analizowanego punktu.
4. Wyjaśnienia przez przykład (ang. *explanations by example*) – ten typ metod wykorzystuje reprezentatywne przykłady z danych treningowych, które są podobne do obserwacji analizowanej. Wyjaśnienie polega na wskazaniu prototypu lub kontrprzykładu, co pozwala użytkownikowi zrozumieć kryteria decyzyjne modelu poprzez analogię do znanych przypadków.
5. Wyjaśnienia przez uproszczenie (ang. *explanations by simplification*) – techniki te polegają na stworzeniu uproszczonego modelu zastępczego, który odwzorowuje zachowanie złożonej czarnej skrzynki. Model taki zachowuje maksymalnie podobne właściwości decyzyjne, przy jednoczesnym zmniejszeniu złożoności i zwiększeniu przejrzystości. Przykładami są drzewa decyzyjne, zbiory reguł czy modele liniowe uczone na wynikach modelu oryginalnego. Tego rodzaju podejścia pozwalają uzyskać globalne wyjaśnienie przy zachowaniu akceptowalnej dokładności.
6. Wyjaśnienia istotności cech (ang. *feature relevance explanations*) – rodzina metod oparta na określaniu wpływu poszczególnych zmiennych wejściowych na wynik modelu. Wskaźniki istotności cech informują, w jakim stopniu dana cecha przyczynia się do zwiększenia lub zmniejszenia wartości predykcji. Wśród popularnych metod tego typu znajdują się SHAP oraz PFI.

Zaletą podejść post-hoc jest ich uniwersalność, ponieważ mogą być stosowane do dowolnych modeli. Umożliwiają także zastosowanie bez potrzeby ponownego uczenia modelu, więc użytkownik może uzyskać interpretację działania już wdrożonego systemu. Ograniczeniem tego podejścia jest natomiast niepewność co do wierności wyjaśnień, czyli zgodności wyjaśnienia z rzeczywistą logiką modelu. Modele zastępcze mogą oddawać jedynie przybliżony obraz procesu decyzyjnego. Dodatkowo, metody lokalne mogą generować wyjaśnienia o niskiej stabilności (niewielka zmiana danych wejściowych może prowadzić do istotnie różnego opisu przyczyn decyzji). Wreszcie, interpretacje post-hoc mają często charakter heurystyczny, co ogranicza ich zastosowanie w kontekstach wymagających formalnej weryfikacji decyzji [11, 30]. Podkreśla się również brak standardów oceny jakości samych wyjaśnień i założenia, które często są nierealistyczne dla prawdziwych danych [4, 12].

Projektowanie modeli transparentnych

Projektowanie z zachowaniem transparentności reprezentuje drugie podejście do problemu interpretowalności wspomniane w definicji. Zakłada ono, że model sam w sobie jest zrozumiały. Modele transparentne stanowią przeciwieństwo czarnych skrzynek, ponieważ są interpretowalne z założenia. Do typowych przykładów należą drzewa decyzyjne, reguły logiczne, modele liniowe czy addytywne modele uogólnione (GAM) [5, 23]. Transparentność modeli można analizować w trzech uzupełniających się wymiarach [5]:

1. Przezrzystość algorytmiczna – zdolność zrozumienia sposobu, w jaki model przechodzi od danych wejściowych do wyników,
2. Dekomponowalność – możliwość interpretacji poszczególnych elementów modelu, takich jak cechy, parametry czy reguły,
3. Symulowalność – zdolność człowieka do odtworzenia i śledzenia procesu decyzyjnego w całości.

Modele transparentne są szczególnie istotne w obszarach, gdzie wymagana jest audytowalność decyzji, np. w diagnostyce medycznej, ocenie ryzyka finansowego lub systemach rekomendacyjnych. Ich głównym ograniczeniem jest natomiast kompromis między interpretowalnością a dokładnością [11, 23]. Niemniej jednak ze względu na te cechy cieszą się nieprzerwaną popularnością w specjalistycznym zakresie zastosowań.

2.3 Analiza istotności cech

Celem niniejszego podrozdziału jest przedstawienie wybranych technik XAI, które znajdują zastosowanie w analizie istotności cech modeli typu *black box*. Omówione zostaną trzy powszechnie stosowane metody: LIME, SHAP oraz PFI. Każda z nich reprezentuje odmienny sposób podejścia do problemu interpretacji działania, umożliwiając zarówno lokalne, jak i globalne wyjaśnianie decyzji algorytmów uczenia maszynowego.

2.3.1 LIME

Metoda LIME (Local Interpretable Model-Agnostic Explanations) została zaproponowana przez Ribeiro, Singh i Guestrina w pracy *Why Should I Trust You? Explaining the Predictions of Any Classifier* [24] w 2016 roku. Należy ona do grupy technik post-hoc, ponieważ służy do wyjaśniania działania już wytrenowanego modelu oraz do metod model-agnostycznych, co oznacza, że może być stosowana niezależnie od rodzaju modelu. Jednocześnie w swoim podstawowym wariantcie jest metodą lokalną, gdyż koncentruje się na interpretacji decyzji dotyczącej pojedynczej obserwacji, zamiast próbować odwzorować zachowanie modelu w całej przestrzeni cech [1].

Zasadnicza idea metody polega na przybliżeniu złożonego modelu w ograniczonym otoczeniu punktu x przy pomocy prostego modelu zastępczego (tzw. *surrogate model*) g , zazwyczaj w postaci

regresji liniowej. Model ten pozwala zrozumieć, które cechy wejściowe w największym stopniu przyczyniły się do otrzymania konkretnej predykcji, co wspiera proces budowania zaufania do systemów opartych na sztucznej inteligencji.

Formalny opis metody LIME można przedstawić jako rozwiązanie problemu optymalizacji:

$$\xi(x) = \arg \min_{g \in G} (L(f, g, \pi_x) + \Omega(g)), \quad (1)$$

gdzie:

- G – zbiór prostych modeli interpretowalnych (np. modele liniowe lub drzewa decyzyjne),
- $L(f, g, \pi_x)$ – funkcja straty mierząca niezgodność między oryginalnym modelem f a lokalnym przybliżeniem g ,
- $\pi_x(z)$ – funkcja wagowa nadająca większe znaczenie próbkom bliższym punktowi x ,
- $\Omega(g)$ – kara za złożoność modelu.

W szczególności, gdy g jest modelem liniowym, funkcja straty przyjmuje postać:

$$L(f, g, \pi_x) = \sum_{z \in Z} \pi_x(z) (f(z) - g(z'))^2, \quad (2)$$

gdzie Z oznacza zbiór perturbacji utworzonych poprzez losowe modyfikacje obserwacji x' . Wagi lokalności określone są za pomocą jądra Gaussa:

$$\pi_x(z) = \exp \left(-\frac{D(x, z)^2}{\sigma^2} \right), \quad (3)$$


przy czym $D(x, z)$ jest miarą odległości pomiędzy próbkami (np. euklidesową lub cosinusową), a parametr σ kontroluje szerokość lokalnego otoczenia.

Model lokalny ma natomiast postać liniową:

$$g(z') = w_g \cdot z', \quad (4)$$

gdzie w_g stanowi wektor wag interpretowalnych cech. Wartości tych wag można interpretować jako miarę wpływu poszczególnych cech na decyzję modelu w danym punkcie. Aby uzyskać interpretację prostą i czytelną, metoda stosuje procedurę K-LASSO, ograniczającą liczbę aktywnych cech do z góry ustalonego poziomu K .

W praktyce LIME znajduje szerokie zastosowanie przy analizie modeli uczenia maszynowego. W języku *Python* technika ta jest zaimplementowana w popularnej bibliotece `lime`, umożliwiającej generowanie lokalnych wyjaśnień dla klasyfikatorów i regresorów. Wynikiem działania algorytmu są wizualizacje przedstawiające wpływ poszczególnych cech na konkretną predykcję. Na rys. 4 poniżej przedstawiono przykładowe wyniki zastosowania metody dla modelu typu MLP uczącego się na danych tabelarycznych. Wykres prezentuje wpływ poszczególnych cech na końcową predykcję modelu w formie wykresu słupkowego i tabeli, a także dokładną predykcję przedstawioną w porównaniu do zakresu odpowiedzi modelu.



Rysunek 4. Wyniki analizy istotności cech uzyskane metodą LIME dla obserwacji, źródło: *opracowanie własne*

Z punktu widzenia praktyki analizy modeli uczenia maszynowego, LIME charakteryzuje się szeregiem istotnych zalet. Przede wszystkim jest to metoda niezależna od struktury modelu. Ponadto, wyjaśnienia generowane przez LIME są intuicyjne i zrozumiałe, a dodatkową zaletą jest uniwersalność zastosowania dla różnych form danych [1]. Niemniej jednak do głównych ograniczeń techniki należy fakt, iż LIME zapewnia jedynie lokalne przybliżenie zachowania modelu, co oznacza, że wyniki nie mogą być interpretowane bezpośrednio w ujęciu globalnym. Oprócz tego, jako że metoda opiera się na losowym próbkowaniu perturbacji, uzyskane wyjaśnienia mogą być wrażliwe na parametry generacji próbek i funkcję lokalności. Kolejnym problemem jest koszt obliczeniowy, wynikający z konieczności wielokrotnego wywoływania modelu typu *black box* w celu wygenerowania perturbacji. Pomimo tych ograniczeń, LIME pozostaje jedną z najczęściej stosowanych metod post-hoc, stanowiąc fundament dla wielu późniejszych technik wyjaśniania [1, 24].

Uogólnienie wyników lokalnych

Lokalny charakter wyjaśnień metody LIME uniemożliwia bezpośrednie porównanie jej wyników z metodami globalnymi stosowanymi w pracy. Autorzy metody: Ribeiro, Singh i Guestrin [24], byli świadomi tych ograniczeń i w celu częściowego rozwiązania tego problemu zaproponowali rozszerzenie SP-LIME (Submodular Pick LIME), wybierające reprezentatywny zestaw obserwacji o największym pokryciu i różnicowaniu cech. Dzięki temu użytkownik uzyskuje bardziej ogólny obraz działania modelu, przy zachowaniu lokalnej interpretowalności poszczególnych przypadków. Koncepcję tę

rozwinęto w pracy *Global Aggregations of Local Explanations for Black Box Models* [16], w której zaproponowano metodę GALE (Global Aggregations of Local Explanations). W kontekście danych tabelarycznych i modeli typu *black box* globalne informacje można uzyskać poprzez uśrednianie wag lokalnych modeli LIME, zgodnie ze wzorem:

$$I_j^{Avg} = \frac{\sum_{i=1}^N |W_{ij}|}{\sum_{i: W_{ij} \neq 0} 1}, \quad (5)$$

gdzie W_{ij} oznacza wagę cechy j dla obserwacji i . Otrzymana wartość I_j^{Avg} reprezentuje średni wpływ danej cechy na predykcję modelu, co umożliwia oszacowanie jej znaczenia w ujęciu globalnym.

Podejście to sprawdza się szczególnie w zadaniach regresyjnych i binarnych klasyfikacjach, gdzie rozkład cech jest względnie jednorodny, umożliwiając porównanie metody z innymi technikami globalnymi [3]. Jednak w przypadku problemów wieloklasowych lub niezrównoważonych danych proste uśrednianie może być niewystarczające, gdyż różnice w znaczeniu cech między klasami prowadzą do utraty informacji. Dlatego w literaturze [16] proponuje się rozszerzenia oparte m.in. na wagowaniu entropią Shannona, które lepiej oddają zróżnicowanie wpływu cech w złożonych modelach. W każdym razie, ze względu na rozpatrywanie problemu regresyjnego, niniejsza praca koncentruje się na podstawowym podejściu uśredniającym w celu umożliwienia odniesienia wyników LIME do reszty wybranych technik.

2.3.2 SHAP

Drugą omawianą metodą jest SHAP (SHapley Additive exPlanations). Została zaproponowana przez Lundberga i Lee w artykule *A Unified Approach to Interpreting Model Predictions*, zaprezentowanym na konferencji w 2017 [17]. Autorzy opracowali ją jako ujednolicony sposób interpretacji predykcji modeli UM oparty na teorii gier kooperacyjnych Shapleya. Celem metody jest wyznaczenie ilościowego wpływu każdej cechy wejściowej na wynik predykcji w sposób zgodny z trzema pożądanymi właściwościami: lokalną dokładnością, brakiem wpływu cech nieobecnych oraz spójnością między modelami. Jest metodą post-hoc i model-agnostyczną. Ponadto jest to metoda lokalna, gdyż oblicza wyjaśnienia dla poszczególnych predykcji, jednak dzięki możliwości agregacji wyników lokalnych może dostarczać także informacji globalnych o zachowaniu modelu. Stanowi to dużo powszechniejsze podejście niż w przypadku techniki LIME i posiada wbudowane wsparcie w wielu bibliotekach.

SHAP łączy wcześniejsze koncepcje wyjaśniania (m.in. LIME, DeepLIFT) w ramach jednej klasy tzw. addytywnych metod przypisywania cech. Wszystkie te techniki można zapisać w postaci uproszczonego modelu liniowego:

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i, \quad (6)$$

gdzie $z'_i \in \{0, 1\}$ oznacza obecność danej cechy w interpretowalnej reprezentacji, a ϕ_i to wartość przypisana cechom (ang. *feature attributions*). SHAP stanowi szczególny przypadek tego modelu,

w którym wartości ϕ_i są wyznaczone zgodnie z aksjomatami Shapleya, co zapewnia unikalność i spójność rozwiązania.

Wartości SHAP dla danej cechy i i obserwacji x wyrażane są zgodnie z równaniem Shapleya:

$$\phi_i(f, x) = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(M - |S| - 1)!}{M!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)], \quad (7)$$

gdzie:

- F – zbiór wszystkich cech,
- S – podzbiór cech nieuwzględniających i ,
- $f_S(x_S)$ – predykcja modelu z wykorzystaniem tylko cech z podzbioru S ,
- współczynniki wagowe wynikają z teorii gier Shapleya i zapewniają równy udział wszystkich możliwych kombinacji cech.


Intuicyjnie, ϕ_i opisuje średni wkład cechy i w wynik modelu, mierzony jako różnica w predykcji po dodaniu tej cechy do każdego możliwego zestawu innych zmiennych. Same wartości SHAP, jak wspomniano, spełniają trzy kluczowe własności:

1. Lokalna dokładność – suma wszystkich wag ϕ_i wraz z wartością bazową ϕ_0 odpowiada predykcji modelu:

$$f(x) = \phi_0 + \sum_i \phi_i, \quad (8)$$

2. Brak wpływu cech nieobecnych – jeśli cecha nie jest obecna w obserwacji, to $\phi_i = 0$,
3. Spójność – jeżeli wpływ cechy na wynik modelu wzrasta, jej przypisana wartość nie może się zmniejszyć.

Powyższe własności prowadzą do wniosku, że istnieje tylko jedno rozwiązanie spełniające te warunki i są to wartości SHAP [17]. Jednakże dokładne wyznaczenie wartości Shapleya jest obliczeniowo kosztowne ($O(2^M)$), dlatego Lundberg i Lee zaproponowali kilka aproksymacji SHAP, z których najważniejsze to: *Kernel SHAP*, *Linear SHAP* i *Deep SHAP*. Dzięki tym wariantom metoda SHAP może być stosowana zarówno do modeli tablicowych, jak i do modeli głębokich, drzew decyzyjnych czy lasów losowych. W podejściu praktycznym SHAP jest wykorzystywany w języku *Python* poprzez implementację w popularnej bibliotece *shap*, umożliwiającą generowanie lokalnych i globalnych wyjaśnień dla klasyfikatorów i regresorów. Biblioteka umożliwia wizualizację danych w różnorodnej formie. Najpopularniejsza forma zakłada prezentację wpływu poszczególnych cech na predykcje z oznaczaniem wartości Shapleya. Na rysunku 5 poniżej przedstawiono przykładowe wyniki zastosowania metody dla modelu typu MLP uczącego się na danych tabelarycznych. Wykres prezentuje wartości Shapleya próbek zbioru w formie wykresu rojowego (ang. *beeswarm*). Na jego podstawie można stwierdzić przykładowo, że duże wartości cechy *HIV/AIDS* przekładają się na ujemne wartości Shapleya i w konsekwencji ujemny wpływ na ostateczny wynik.



Rysunek 5. Wyniki analizy istotności cech uzyskane metodą SHAP dla zbioru, źródło: *opracowanie własne*

Zgodnie z wynikami badań Lundberga i Lee [17], największą zaletą SHAP jest teoretyczna spójność i jednoznaczność wyników, wynikająca z podstaw w teorii gier. Metoda zapewnia dokładność lokalną, co oznacza, że suma wszystkich wkładów cech dokładnie rekonstruuje wynik modelu. SHAP umożliwia również porównywanie znaczenia cech między modelami, ponieważ wartości mają interpretację addytywną i zachowują te same własności niezależnie od struktury modelu. Do wad należy jednak przede wszystkim wysoki koszt obliczeniowy, szczególnie przy dużej liczbie cech oraz w przypadku modeli nieliniowych, co wymaga stosowania aproksymacji. Ponadto, podobnie jak inne techniki post-hoc, SHAP opisuje zachowanie modelu, a nie przyczyny zjawiska w danych, co skutkuje ryzykiem ludzkiej nadinterpretacji [14]. Wspólnie z większością technik dzieli również problem podatności na wartości skorelowane [27].

2.3.3 PFI

Technika PFI (Permutation Feature Importance) została pierwotnie zaproponowana przez Breimana w pracy *Random Forests* [6] jako wewnętrzny mechanizm oceny znaczenia zmiennych w modelach zespołowych, zwłaszcza w lasach losowych. Breiman wykazał, że przetasowanie wartości pojedynczej zmiennej w zbiorze danych testowych prowadzi do wzrostu błędu predykcji. Jednocześnie skala

tego wzrostu odzwierciedla istotność danej cechy dla modelu. W konsekwencji wysnuł wniosek, że zmienna, której losowe przetasowanie powoduje największy spadek jakości predykcji, jest uznawana za najbardziej wpływową. W pierwotnej koncepcji technika ta nie była generyczna, gdyż była obliczana w kontekście konkretnego modelu lasu losowego. W kolejnych latach metoda została uogólniona i opisana w wersji model-agnostycznej w pracy *All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously* [10]. W tej postaci PFI może być stosowana do dowolnego modelu uczenia maszynowego, niezależnie od jego struktury wewnętrznej (np. sieci neuronowych, drzew decyzyjnych, regresji czy modeli zespołowych). Zasadnicza idea metody pozostaje niezmienną – mierzy się spadek jakości modelu po losowym przetasowaniu wartości danej cechy, bez zmieniania pozostałych zmiennych. W konsekwencji swoich założeń, metoda ta ma charakter post-hoc i globalny, oraz stanowi jedno z najczęściej stosowanych technik, plasując się na czwartym miejscu pod tym względem według niektórych rankingów [12, 13].

Z perspektywy matematycznej należy to rozpatrywać, że $\hat{f} : \mathbb{R}^p \rightarrow \mathbb{R}$ jest modelem predykcyjnym, a $L(y, \hat{f}(x))$ funkcją straty oceniającą jakość predykcji. Dla danej cechy X_j istotność w ujęciu PFI definiuje się jako różnicę między błędem modelu na danych oryginalnych a błędem po losowym przetasowaniu wartości tej cechy:

$$PFI_j = \mathbb{E}[L(Y, \hat{f}(\tilde{X}_j, X_{-j}))] - \mathbb{E}[L(Y, \hat{f}(X))], \quad (9)$$

gdzie:

- $\tilde{X}_j$ – wektor wartości cechy X_j po losowej permutacji,
- X_{-j} – wszystkie pozostałe cechy,
- L – wybrana funkcja błędu (np. MSE lub MAE).

W praktyce wynik aproksymuje się estymatorem:

$$\widehat{PFI}_j = \frac{1}{n} \sum_{i=1}^n [L(y^{(i)}, \hat{f}(\tilde{x}_j^{(i)}, x_{-j}^{(i)})) - L(y^{(i)}, \hat{f}(x^{(i)}))], \quad (10)$$

gdzie n to liczba obserwacji. Dodatnie wartości PFI_j wskazują, że dana zmienna jest istotna dla modelu, gdyż jej przetasowanie powoduje wzrost błędu predykcji.

W wersji uogólnionej PFI stanowi niezależne od architektury narzędzie oceny wpływu cech. Podkreśla się również jej uniwersalność, intuicyjną interpretację i globalny charakter, co często stanowi przesłankę do wykorzystania jej jako wstępną technikę XAI w wielu zastosowaniach. W konsekwencji niewielkiego skomplikowania teoretycznego, często użycie tej metody jest realizowane poprzez własną implementację, ale istnieją również gotowe rozwiązania jak np. funkcja `sklearn.inspection.permutation_importance`. Ograniczeniem klasycznej wersji PFI jest założenie niezależności cech. W przypadku silnych korelacji między zmiennymi, przetasowanie jednej z nich prowadzi do powstania nienaturalnych kombinacji wartości, które nie występują w rzeczywistym rozkładzie danych. Skutkuje to przeszacowaniem lub niedoszacowaniem znaczenia cech. Ponadto, wynik PFI zależy od przyjętej funkcji błędu.

Rozdział 3

Dane

Celem poniższej sekcji jest przedstawienie dwóch zestawów danych wykorzystanych w badaniach eksperymentalnych: *Life Expectancy (WHO)* oraz *Hospital Length of Stay (Microsoft)*. Zbiory te zostały dobrane w sposób umożliwiający trenowanie zarówno prostych, interpretowalnych modeli, jak i złożonych struktur nieliniowych. Wybór takich danych pozwala nie tylko porównać skuteczność modeli, lecz przede wszystkim zweryfikować spójność i wiarygodność technik wyjaśnialności w zróżnicowanych wariantach problemów.

Kryteria doboru zbiorów

Dobór danych oparto na następujących przesłankach:

1. Zbiory powinny umożliwiać trenowanie zarówno modeli liniowych (np. regresji), jak i nieliniowych (np. MLP, XGBoost), co pozwala analizować zgodność rankingów ważności cech w porównywalnych warunkach jakości predykcji.
2. Zmiennie objaśniające powinny być intuicyjne i łatwe do interpretacji, aby można było ocenić racjonalność wyników uzyskiwanych przez metody XAI bez potrzeby wiedzy eksperckiej.
3. Liczebność danych musi umożliwiać trening modeli o zróżnicowanej złożoności bez ryzyka nadmiernego dopasowania, ale również musi być wystarczająca dla rozbudowanych architektur sieci neuronowych.
4. Preferowano zbiory z domen, w których interpretowalność modeli ma kluczowe znaczenie dla wiarygodności decyzji.
5. Zadania predykcyjne miały być stosunkowo proste, tak aby zasadniczym przedmiotem badań pozostała analiza technik XAI, a nie strojenie modeli.

3.1 Zbiór 1: Life Expectancy (WHO)


Zbiór *Life Expectancy*, opracowany przez Światową Organizację Zdrowia, stanowi zgromadzenie danych dotyczących oczekiwanej długości życia w różnych krajach w latach 2000–2015. Dane obejmują 193 kraje i 22 cechy opisujące aspekty społeczne, ekonomiczne, demograficzne i zdrowotne populacji. W badaniach WHO podkreślano znaczenie szczepień ochronnych, czynników demograficznych, umieralności niemowląt i dorosłych, a także wpływu takich wskaźników jak BMI, PKB czy edukacja na długość życia. Sam zbiór ma charakter regresyjny, a zmienną objaśnianą jest *Oczekiwana długość życia* (w latach). Zbiór stanowi przykład problemu, w którym interpretacja ważności cech ma znaczenie praktyczne, ponieważ pozwala wskazać, które czynniki (np. edukacja, zaszczepienie, dochody, styl życia) w największym stopniu wpływają na długość życia w danym kraju. W tabeli 1 przygotowano zestawienie nazw cech w tłumaczeniu na język polski, wraz z krótkim wyjaśnieniem.

Tabela 1. Zbiór *Life Expectancy* (WHO) — wybrane cechy i ich opis.

Cecha	Opis
Kraj	Identyfikator kraju.
Rok	Rok obserwacji.
Status	Status rozwoju kraju (rozwinięty/rozwijający się).
Oczekiwana długość życia	Zmienna docelowa (lata).
Śmiertelność dorosłych	Wskaźnik umieralności dorosłych.
Zgony niemowląt	Liczba zgonów dzieci < 1 roku.
Alkohol	Konsumpcja alkoholu per capita.
WZW B	Wskaźnik szczepień przeciw WZW typu B.
Odra	Zachorowania na odrę.
BMI	Średni wskaźnik masy ciała populacji.
Polio	Wskaźnik szczepień przeciw polio.
Wydatki całkowite	Całkowite wydatki na zdrowie.
Błonica	Wskaźnik szczepień przeciw błonicy.
HIV/AIDS	Występowanie HIV/AIDS.
PKB	Produkt Krajowy Brutto.
Populacja	Liczba ludności.
Niedowaga 1–19 lat	Odsetek niedowagi wśród dzieci/młodzieży.
Skład dochodu z zasobów	Wskaźnik społeczno-ekonomiczny.
Lata edukacji	Średnia liczba lat edukacji.

Macierz korelacji

Analiza macierzy korelacji zaprezentowana na rys. 6 wskazuje, że większość cech jest słabo lub umiarkowanie skorelowana. Jedyną istotną zależnością jest związek pomiędzy *Lata edukacji* a *Skład dochodu z zasobów* ($r \approx 0,77$). Literatura nie określa jednoznacznie progu kolinearności, lecz najczęściej za istotne uznaje się wartości powyżej $|r| > 0,7$ [8]. Z uwagi na znaczenie interpretacyjne obu cech zdecydowano się nie usuwać ich ze zbioru, co pozwala ocenić wpływ na techniki XAI.



Rysunek 6. Macierz korelacji cech — zbiór *Life Expectancy* (WHO)

3.2 Zbiór 2: Hospital Length of Stay (Microsoft)


Zbiór *Hospital Length of Stay* został opracowany przez firmę Microsoft w ramach publicznego projektu dotyczącego modelowania długości pobytu pacjentów w szpitalu. Dane obejmują około 100 tysięcy rekordów opisujących hospitalizacje, a każda obserwacja zawiera zarówno zmienne kliniczne (np. wartości biochemiczne, diagnozy, stany chorobowe), jak i dane administracyjne. Zmienną przewidywaną jest *Długość pobytu (dni)*. Kontekst medyczny sprawia, że interpretowalność modeli ma istotne znaczenie, a wyniki wyjaśnień mogą wskazywać, które parametry najbardziej wpływają na długość hospitalizacji. Analogicznie w tabeli 2 przedstawiono, krótkie zestawienie cech tego zbioru danych opatrzone krótkim wyjaśnieniem.

Tabela 2. Zbiór *Hospital Length of Stay* — wybrane cechy i ich opis

Cecha	Opis
Liczba wizyt	Liczba ponownych przyjęć w ostatnich 180 dniach.
Płeć	Płeć pacjenta (M/F).
Schyłkowa niewydolność nerek (dializa)	Flaga współwystępowania schorzenia.
Astma	Flaga rozpoznania astmy.
Niedobór żelaza	Flaga niedoboru żelaza.
Zapalenie płuc	Flaga zapalenia płuc.
Uzależnienie od substancji	Flaga uzależnienia.
Poważne zaburzenie psychiczne	Flaga rozpoznania.
Depresja	Flaga rozpoznania depresji.
Psychoterapia	Flaga odbywania psychoterapii.
Zwłóknienie i inne schorzenia	Flaga rozpoznania chorób włóknieniowych.
Niedożywienie	Flaga niedożywienia.
Poziom hemoglobiny	Średnia wartość w trakcie pobytu (g/dL).
Hematokryt	Średnia wartość w trakcie pobytu (g/dL).
Neutrofile	Średnia liczba komórek (na μL).
Sód	Średnie stężenie sodu (mmol/L).
Glukoza	Średnie stężenie glukozy (mmol/L).
Azot mocznikowy we krwi (BUN)	Średnie stężenie (mg/dL).
Kreatynina	Średnie stężenie (mg/dL).
Wskaźnik masy ciała (BMI)	Średni wskaźnik masy ciała (kg/m^2).
Tętno	Średnia liczba uderzeń serca na minutę.
Częstość oddechów	Średnia liczba oddechów na minutę.
Dodatkowa diagnoza (nie-ICD9)	Flaga dodatkowej diagnozy spoza ICD9.
ID placówki	Identyfikator placówki medycznej.
Długość pobytu (dni)	Zmienna docelowa.

Macierz korelacji

Analiza macierzy korelacji z rys. 7 wskazuje, że cechy w tym zbiorze są w dużej mierze niezależne. Najwyższy współczynnik korelacji uzyskano pomiędzy zmiennymi *Psychoterapia* oraz *Azot mocznikowy we krwi (BUN)* ($r \approx 0,34$). Tak niskie wartości świadczą o braku silnych relacji liniowych pomiędzy zmiennymi, co pozwala ocenić techniki XAI w warunkach minimalnej kolinearności.



Rysunek 7. Macierz korelacji cech — zbiór *Hospital Length of Stay (Microsoft)*

Rozdział 4

Prace eksperymentalne

Celem niniejszego rozdziału jest przedstawienie i omówienie wyników przeprowadzonych prac eksperymentalnych, których zasadniczym zadaniem było porównanie działania wybranych technik wyjaśnialnej sztucznej inteligencji wprowadzonych w rozdziale poświęconemu zagadnieniom teoretycznym 2, tj. *Permutation Feature Importance* (PFI), *Local Interpretable Model-Agnostic Explanations* (LIME) oraz *SHapley Additive exPlanations* (SHAP). Analiza została ukierunkowana na ocenę jakości i spójności wyników generowanych przez poszczególne metody w kontekście określania ważności cech dla różnych modeli UM.

W pierwszej części rozdziału przedstawiono przyjętą metodologię badań oraz szczegóły implementacyjne, obejmujące strukturę eksperymentów, dobór danych oraz konfigurację środowiska. Następnie omówiono wyniki uzyskane dla różnych architektur modelu typu wielowarstwowego perceptronu, aby w dalszej części praca została rozszerzona o eksperymenty z innymi popularnymi modelami uczenia maszynowego, takimi jak *Decision Tree*, *Random Forest*, regresja liniowa oraz *Extreme Gradient Boosting*. Wnioski z przeprowadzonych badań umożliwiają pogłębioną ocenę spójności, stabilności oraz użyteczności poszczególnych technik XAI w kontekście praktycznych zastosowań.

4.1 Metodologia

Proces badawczy obejmował kilka etapów. W pierwszej kolejności dokonano przygotowania danych, co obejmowało podział na zbiór uczący i testowy w proporcji 80/20 oraz skalowanie zmiennych objaśniających do przedziału $[0, 1]$. Następnie dla każdego z wybranych zestawów danych wytrenowano 18 modeli MLP o zróżnicowanej architekturze, obejmującej różne liczby warstw ukrytych, liczbę neuronów oraz funkcję aktywacji. Proces selekcji odpowiednich parametrów wykorzystywał technikę *grid search* wykorzystującą kombinację wskazanych hiperparametrów. Ważnym aspektem było dobranie takiego zakresu parametrów, aby porównywane architektury osiągnęły satysfakcjonujące wyniki predykcyjne, co umożliwiło przeprowadzenie analizy technik XAI niezależnie od jakości dopasowania, ale z uwzględnieniem wpływu różnych wariantów tego samego modelu. W dalszej części badań dla wszystkich skonstruowanych modeli obliczono wartości globalnej ważności cech

z wykorzystaniem technik LIME, SHAP i PFI, analizując ich stabilność, zgodność oraz wrażliwość na zmiany architektury. Na podstawie uzyskanych wyników wybrano najlepszy model MLP dla każdego zestawu danych i wykorzystano go jako punkt odniesienia w porównaniu z innymi rodzinami modeli uczenia maszynowego, takimi jak regresja liniowa, drzewa decyzyjne, lasy losowe oraz XGBoost. Proces ten umożliwił kompleksową ocenę działania technik XAI zarówno w kontekście modeli głębokich, jak i klasycznych, o zróżnicowanej złożoności.

4.2 Implementacja

Poniższa sekcja jest przedstawieniem opracowanej implementacji w formie uproszczonego interfejsu, którego celem jest umożliwienie spójnego i powtarzalnego przeprowadzenia badań eksperymentalnych. Implementacja obejmuje dwie klasy: `ModelData` (warstwa trenowania modeli) oraz `EvaluateData` (warstwa ewaluacji i obliczania wyjaśnień), które wspólnie realizują cały proces uczenia maszynowego z warstwą XAI.

W pracy przyjęto następujące założenia:

1. Separację odpowiedzialności – `ModelData` odpowiada za przygotowanie i trenowanie modeli, a `EvaluateData` za metryki jakości oraz globalne ważności cech.
2. Spójny interfejs modelowania – niezależnie od biblioteki bazowej (`scikit-learn`, `XGBoost`, `Keras/TensorFlow`) przewidywania są przeprowadzone w identyczny sposób, a techniki wyjaśniania działają niezależnie od wybranego modelu.
3. Powtarzalność – kontrola losowości oraz stałe punkty podziału danych i próbkowania dla metod XAI.

Interfejs klasy ModelData

Poniżej zaprezentowano uproszczony pseudokod interfejsu klasy ModelData. Składnia ma charakter poglądowy i może być interpretowana jako schemat wysokopoziomowy implementacji. Klasa ModelData zapewnia walidację wejścia (X, y), rejestrowanie modeli oraz historii uczenia i gotowe moduły trenowania dla modeli. Historia uczenia (jeśli występuje) jest buforowana w polach dla celów dalszej analizy.

```

1 class ModelData:
2     def __init__(self, train: (DataFrame, Series), test: (DataFrame, Series
3         )):
4         pass
5
6     def linear_regression(self, name="linear_regression", **kwargs) ->
7         ModelData:
8         pass
9
10    def decision_tree(self, name="decision_tree", max_depth=None,
11        random_state=42, **kw) -> ModelData:
12        pass
13
14    def random_forest(self, name="random_forest", n_estimators=500,
15        max_depth=None,
16        random_state=42, n_jobs=-1, **kw) -> ModelData:
17        pass
18
19    def xgboost(self, name="xgboost", epochs=500, params=None,
20        early_stopping_rounds=10, test_size=0.2, random_state=42)
21    -> ModelData:
22        pass
23
24    def mlp(self, name="mlp", model=None, epochs=500, validation_split=0.2,
25        patience=10,
26        batch_size=None, optimizer="adam", loss="mse", metrics=["mae", "
27        mse"]) -> ModelData:
28        pass

```

Listing 1. Uproszczony interfejs klasy ModelData

Interfejs EvaluateData

Klasa EvaluateData przyjmuje instancję ModelData jako argument wejściowy i dostarcza metryki oraz agregacje ważności cech. Zapewnia również obliczanie metryk jakości (RMSE, MAE, R^2) dla zbiorów treningowego i testowego, estymację globalnych ważności cech trzema metodami: SHAP (Tree/Linear/Kernel), LIME (średnia wartość bezwzględna wkładów) oraz PFI (spadek jakości po permutacji, zgodnie z interfejsem *scikit-learn*), co zostało przedstawione w poniższym pseudokodzie.

```

1 class EvaluateData:
2     init(model_data: ModelData)
3
4     evaluate_all() -> DataFrame
5
6     plot_model_metrics(model_names=None, metrics=("RMSE", "MAE", "R2"),
7                       dataset="both", skip_calculation=False, show_tables=
8     True)
9
10    compute_feature_importances(methods=("SHAP", "LIME", "PFI"),
11                                K=100, shap_background=100, shap_nsamples
12    =100,
13                                lime_num_features=None, lime_n_samples
14    =5000,
15                                pfi_n_repeats=10, pfi_scoring="
16    neg_mean_squared_error",
17                                random_state=42) -> DataFrame
18
19    plot_feature_importances(model_names=None, methods=("SHAP", "LIME", "PFI"
20    ),
21                                K=100, scale_01=False, skip_calculation=False,
22    display_mode="per_model", **kwargs) -> dict[
23    str, Figure]
24
25    importance_correlation(model_names, methods=("SHAP", "LIME", "PFI"),
26                            top_n=None, abs_values=False, scale_01=False,
27                            skip_calculation=False, show_plot=True,
28                            title=None, ncols=None, corr_method="spearman")
29    -> dict[str, DataFrame]
30
31    compare_feature_importance(model_name: str, methods: Iterable[str],
32                                skip_calculation=False, **kwargs) -> dict[
33    str, list[str]]

```

Listing 2. Uproszczony interfejs klasy EvaluateData

Wykorzystane biblioteki

Tabela 3 przedstawia nazwy i wersje bibliotek języka *Python*, które zostały wykorzystane w procesie implementacji. Wymienione biblioteki *lime* i *shap* stanowią podstawę wykorzystania technik XAI, nad którą została zaimplementowana wyższa warstwa abstrakcji w postaci opisanych klas.

Tabela 3. Zestawienie bibliotek kluczowych dla warstwy modeli i XAI

Biblioteka	Wersja
numpy	2.1.3
pandas	2.2.3
scikit-learn	1.6.1
xgboost	3.0.0
tensorflow	2.19.0
keras	3.9.2
shap	0.47.2
lime	0.2.0.1
plotly	6.0.1

4.3 Sieci neuronowe

Zgodnie z założeniami metodologii jedno z pierwszych przeprowadzonych badań dotyczą analizy zachowania technik wyjaśnialnej sztucznej inteligencji dla różnych architektur sieci neuronowych typu perceptron wielowarstwowy (MLP). W celu komplementarnego zbadania tego zagadnienia wytrenowano łącznie osiemnaście modeli dla każdego zestawu danych będących kombinacjami trzech głównych parametrów architektury:

- liczby warstw ukrytych: 2, 3 lub 4,
- funkcji aktywacji: tanh oraz ReLU,
- liczby neuronów w warstwie: 64, 128, 256.

Zastosowany zbiór konfiguracji stanowi podzbiór szerszego zestawu testowych kombinacji, który zapewnia satysfakcjonujące wyniki dla obu zbiorów. W niniejszej pracy uwzględniono jedynie te modele, które zapewniły wyniki uznane za praktyczne pod względem błędu predykcji.

4.3.1 Skuteczność modeli

W celu oceny jakości wytrenowanych modeli MLP wykorzystano trzy powszechnie stosowane metryki błędu regresji: RMSE (*Root Mean Squared Error*), MAE (*Mean Absolute Error*), R^2 (*Coefficient of Determination*). Na rys. 8a–8b oraz w tabelach 4a–4b przedstawiono wyniki uzyskane dla zbioru testowego w przypadku obu zestawów danych. Z analizy rezultatów pierwszego zestawu (8a, 4a) wynika, że 15 spośród 18 modeli zapewnia satysfakcjonujące błędy predykcji na zbiorze testowym, przy czym wartości metryk mieszczą się w zakresie od 2,427 do 3,353 dla RMSE i od 1,717 do 2,655 dla MAE. Najlepsze wyniki osiągnęła architektura 256–256 (ReLU), uzyskując dla zbioru testowego błędy:

$$\text{RMSE} = 2,427263, \quad \text{MAE} = 1,716969, \quad R^2 = 0,917046.$$

Wartości te są najlepsze spośród wszystkich testowanych modeli dla wszystkich trzech metryk, co potwierdza wysoką zdolność uogólniania przy jednoczesnym braku nadmiernego dopasowania. Zarówno tabela 4a, jak i wykres na rysunku 8a wskazują, że jedynie trzy modele odbiegają znacząco od średniej: 128–128–128–128 (tanh), 64–64–64–64 (tanh), 256–256–256–256 (tanh). Dla tych architektur uzyskano znacznie wyższe błędy ($\text{RMSE} > 8,45$ i $\text{MAE} > 6,89$). Jest to prawdopodobnie spowodowane faktem, że nadmierna głębokość sieci z funkcją tanh może prowadzić do trudności w optymalizacji.

Analogicznie wyniki drugiego zbioru danych (8b, 4b) pozwalają stwierdzić, iż wszystkie modele uzyskują podobnie dobre wyniki z zakresu od 0,530 do 0,609 dla RMSE i od 0,371 do 0,410 dla MAE. Najlepszą architekturą okazała się w tym wypadku 64–64–64 (tanh), uzyskując dla zbioru testowego następujące błędy:

$$\text{RMSE} = 0,529620, \quad \text{MAE} = 0,371315, \quad R^2 = 0,948881.$$

Wyniki w tym wariancie są zdecydowanie mniej zróżnicowane i żadna z architektur nie odbiega wyraźnie uzyskanymi wynikami od średniej. Pozwala to stwierdzić, że każdy z modeli MLP mógłby zostać użyty z podobnym skutkiem do modelowania tego problemu regresyjnego.



(a) Zestaw *Life Expectancy*(b) Zestaw *Hospital Length of Stay***Rysunek 8.** Porównanie metryk testowych modeli MLP dla dwóch zestawów danych

Tabela 4. Porównanie dokładnych błędów testowych modeli MLP dla dwóch zestawów danych


(a) Zestaw <i>Life Expectancy</i>				(b) Zestaw <i>Hospital Length of Stay</i>			
Model	RMSE	MAE	R ²	Model	RMSE	MAE	R ²
256-256 (relu)	2,427263	1,716969	0,917046	64-64-64 (tanh)	0,529620	0,371315	0,948881
128-128-128 (relu)	2,445558	1,771565	0,915791	128-128-128 (tanh)	0,531015	0,367909	0,948612
64-64-64 (relu)	2,531690	1,751629	0,909755	256-256-256 (tanh)	0,542045	0,382442	0,946455
256-256-256 (relu)	2,668347	1,940287	0,899749	64-64-64 (tanh)	0,551843	0,365347	0,944502
256-256-256-256 (relu)	2,746687	2,010384	0,893776	64-64 (tanh)	0,552366	0,416382	0,944396
64-64-64-64 (relu)	2,780136	2,009122	0,891173	64-64-64 (relu)	0,554545	0,368390	0,943957
128-128-128-128 (relu)	2,816673	2,051957	0,888294	128-128 (tanh)	0,556990	0,391450	0,943642
128-128 (relu)	3,011121	2,257653	0,872338	64-64 (relu)	0,563704	0,391408	0,942090
64-64 (tanh)	3,161985	2,449377	0,859226	256-256 (tanh)	0,563863	0,417894	0,942058
128-128-128 (tanh)	3,162769	2,445530	0,859156	256-256-256 (tanh)	0,570692	0,394926	0,940646
64-64-64-64 (tanh)	3,174591	2,469441	0,858101	64-64-64 (relu)	0,571845	0,394293	0,940430
128-128 (tanh)	3,177569	2,453501	0,857835	128-128-128-128 (tanh)	0,572109	0,389858	0,940364
256-256 (tanh)	3,210344	2,470597	0,855698	128-128 (relu)	0,583278	0,401046	0,937999
64-64-64 (tanh)	3,330504	2,539199	0,843820	256-256-256 (relu)	0,583590	0,390665	0,937932
256-256-256 (tanh)	3,353173	2,654569	0,841687	128-128-128 (relu)	0,584690	0,393696	0,937698
256-256-256-256 (tanh)	8,455211	6,892989	-0,006591	256-256-256-256 (relu)	0,585610	0,389159	0,936593
64-64-64-64 (tanh)	8,462328	6,912591	-0,008286	128-128-128-128 (relu)	0,590895	0,405943	0,935411
128-128-128-128 (tanh)	8,462525	6,913315	-0,008333	256-256 (relu)	0,609120	0,409876	0,932383

4.3.2 Techniki XAI


W tym miejscu przedstawiono rezultaty analiz ważności cech uzyskane przy zastosowaniu trzech wybranych technik. Wszystkie wyniki zostały przygotowane z wykorzystaniem opisanego wcześniej środowiska eksperymentalnego i implementacji zaprezentowanej we wcześniejszej sekcji (4.2). Dokładniejsze szczegóły procesu przeprowadzania eksperymentów zostały również omówione w sekcji dedykowanej metodologii (4.1).

Dla każdej z technik spreparowano dwa typy wizualizacji:


- Wykresy słupkowe (rys. 9–14) przedstawiają pojedyncze wartości ważności cech dla 15 różnych modeli MLP i dwóch zestawów danych. Każdy słupek odpowiada pojedynczej cesze, a jego długość reprezentuje wagę nadaną przez daną technikę.
- Wykresy pudełkowe (rys. 15–20) prezentują dane z wykresów słupkowych w formie zagregowanej. Każda tzw. *pudełko* odpowiada jednej cesze i obrazuje: średnią (pionowa linia przerywana), medianę (pionowa linia ciągła), kwartyle (tzw. *wąsy* i *pudełko*), odchylenie standardowe (trójkąty przerywane) oraz wartości odstające (punkty).




Rysunek 9. Wykres słupkowy ważności cech – technika SHAP i zestaw *Life Expectancy*




Rysunek 10. Wykres słupkowy ważności cech – technika PFI i zestaw *Life Expectancy*




Rysunek 11. Wykres słupkowy ważności cech – technika LIME i zestaw *Life Expectancy*




Rysunek 12. Wykres słupkowy ważności cech – technika SHAP i zestaw *Hospital Length of Stay*


Rysunek 13. Wykres słupkowy ważności cech – technika PFI i zestaw *Hospital Length of Stay*




Rysunek 14. Wykres słupkowy ważności cech – technika LIME i zestaw *Hospital Length of Stay*



Rysunek 15. Wykres pudełkowy ważności cech – technika SHAP i zestaw *Life Expectancy*





Rysunek 16. Wykres pudełkowy ważności cech – technika PFI i zestaw *Life Expectancy*




Rysunek 17. Wykres pudełkowy ważności cech – technika LIME i zestaw *Life Expectancy*

Rozkład ważności per cecha dla metody: SHAP

Rysunek 18. Wykres pudełkowy ważności cech – technika SHAP i zestaw *Hospital Length of Stay*



Rysunek 19. Wykres pudełkowy ważności cech – technika PFI i zestaw *Hospital Length of Stay*



Rysunek 20. Wykres pudełkowy ważności cech – technika LIME i zestaw *Hospital Length of Stay*



Analiza przedstawionych powyżej wykresów (9-20) pozwala wykazać, że architektura sieci MLP ma istotny wpływ na rozkład ważności cech przypisywanych przez każdą z technik. Zależność ta jest widoczna we wszystkich trzech przypadkach: LIME, SHAP i PFI, a szczególnie zyskuje na znaczeniu w przypadku pierwszego zestawu danych powiązanych z wykresami 9–11. Dodatkowo wizualizacje w formie wykresów pudełkowych 15–17 uwiadamiają, że cechy *Skład dochodu z zasobów* oraz *HIV/AIDS* konsekwentnie zajmują dwa najwyższe miejsca we wszystkich wykresach pudełkowych, uzyskując średnią skalowaną ważność powyżej 0,660 niezależnie od zastosowanej metody. Pomimo tej zgodności, zakres ich wartości jest bardzo zróżnicowany między technikami. Dla przykładu w przypadku PFI zakres ważności cechy „*Skład dochodu z zasobów*” wynosi od 0,149 do 1,000, a w LIME ta sama cecha mieści się w przedziale od 0,839 do 1,000 (5-krotnie mniejszy zakres), co sugeruje, że metoda LIME jest bardziej jednoznaczna w określaniu dominującej cechy dla tego problemu. Odmienne dynamiki zmienności charakteryzuje drugi problem, gdzie wykresy 12–14 wykazują o wiele mniejszą zmienność pomiędzy różnymi architekturami. W tym wypadku cechy

Liczba wizyt i *Poważne zaburzenia psychiczne* konsekwentnie plasują się na pierwszym miejscu. Zagregowanie danych w formie wykresów 18–18 potwierdza mniejszy zakres zmienności wszystkich cech w obrębie wszystkich technik. Największą rozpiętość uzyskała cecha *Poważne zaburzenia psychiczne* dla techniki LIME przypisując wagi z zakresu od 0,014 do 0,301.

Analiza wykresów słupkowych pierwszego zestawu (9–11) wskazuje ponadto, że dominacja cechy *HIV/AIDS* w ramach konkretnego modelu prowadzi do zmniejszenia ważności przypisywanej drugiej z najważniejszych cech *Skład dochodów z zasobów*. Sugeruje to, że model MLP w tym wypadku opiera się głównie na jednej z tych zmiennych, a obie cechy mogą opisywać częściowo zbliżone zjawiska. Ponadto zakres zmienności pomiędzy architekturami jest największy dla pierwszych sześciu cech o najwyższej średniej ważności. Cechy uznawane za mniej istotne wykazują większą stabilność, jednak ich ranking i relatywne wartości różnią się w zależności od techniki. Interesującym przypadkiem są również zmienne, które uzyskały wartości ważności z bardzo szerokiego zakresu, co wskazuje na silną zależność od konkretnej architektury modelu. Dla *Lata edukacji* wartości mieściły się w przedziale od 0,020 do 0,970 przy zastosowaniu techniki SHAP. Zmienna *Status* osiągnęła zakres od 0,088 do 1,000 w analizie prowadzonej z wykorzystaniem metody LIME. Natomiast *Skład dochodu z zasobów* charakteryzował się wartościami od 0,150 do 1,000, zgodnie z wynikami uzyskanymi dla techniki PFI. Oznacza to, że te same cechy mogą być uznawane za kluczowe przez jedne modele, a niemal nieistotne przez inne, co podkreśla znaczenie kontekstu architektury przy interpretacji wyników metod XAI.

Analiza szczegółowa

Dalsze badania koncentrują się na dwóch najlepszych modelach o najmniejszych uzyskanych błędach, wybranych w sekcji poświęconej błędom modeli 4.3.1, tj. architekturach 256-256 (*ReLU*) i 64-64-64 (*tanh*) w przypadku odpowiednio pierwszego i drugiego zestawu danych. Dla każdego z tych modeli przygotowano zestawienia wyników w postaci wykresów słupkowych, w których poszczególne serie danych odpowiadają trzem zastosowanym technikom (21a–21b). W każdym przypadku wykres pozwala na bezpośrednie porównanie względnych wartości ważności cech przypisanych przez poszczególne metody, a różnice pomiędzy nimi pozwalają zrozumieć, w jakim stopniu wybór techniki wpływa na interpretację modelu.

(a) Zestaw *Life Expectancy*(b) Zestaw *Hospital Length of Stay***Rysunek 21.** Porównanie ważności cech dla dwóch najlepszych modeli MLP

W celu zweryfikowania spójności dla każdego najlepszego modelu przygotowano także tabele 5a–5b przedstawiające ranking cech w kolejności malejącej ważności dla każdej z technik. Kolor zielony zastosowany w wierszach oznacza te cechy, które zostały wskazane na dokładnie tym samym miejscu przez wszystkie trzy metody, co pozwala w sposób bezpośredni ocenić zgodność technik względem siebie.

Tabela 5. Porównanie rankingów ważności cech dla dwóch modeli MLP

(a) Zestaw *Life Expectancy*

	SHAP	PFI	LIME
0	Skład dochodu z zasobów	Skład dochodu z zasobów	Skład dochodu z zasobów
1	Śmiertelność dorosłych	Śmiertelność dorosłych	Status
2	HIV/AIDS	HIV/AIDS	HIV/AIDS
3	Niedowaga 1–19 lat	Status	Śmiertelność dorosłych
4	Status	Niedowaga 1–19 lat	Niedowaga 1–19 lat
5	Alkohol	Alkohol	Zgony niemowląt
6	Wydatki całkowite	Lata edukacji	Polio
7	Polio	Zgony niemowląt	Błonica
8	Lata edukacji	PKB	PKB
9	Zgony niemowląt	Kraj	WZW B
10	Kraj	Polio	Wydatki całkowite
11	WZW B	Populacja	Lata edukacji
12	Błonica	Wydatki całkowite	Kraj
13	BMI	BMI	Alkohol
14	PKB	Błonica	Populacja
15	Rok	Rok	BMI
16	Populacja	WZW B	Odra
17	Odra	Odra	Rok


(b) Zestaw *Hospital Length of Stay*

	SHAP	PFI	LIME
0	Liczba wizyt	Liczba wizyt	Liczba wizyt
1	Poważne zaburzenie psychiczne	Poważne zaburzenie psychiczne	Poważne zaburzenie psychiczne
2	Sód	Hematokryt	Niedobór żelaza
3	Wskaźnik masy ciała (BMI)	Glukoza	Poziom hemoglobiny
4	Glukoza	Wskaźnik masy ciała (BMI)	Azot mocznikowy we krwi (BUN)
5	Tętno	Niedobór żelaza	Uzależnienie od substancji
6	Hematokryt	Tętno	Psychoterapia
7	Kreatynina	Kreatynina	Zapalenie płuc
8	Częstość oddechów	Sód	Astma
9	Niedobór żelaza	Poziom hemoglobiny	Depresja
10	Astma	Uzależnienie od substancji	Niedożywienie
11	Poziom hemoglobiny	Częstość oddechów	Schyłkowa niewydolność nerek (dializa)
12	Neutrofile	Astma	Częstość oddechów
13	Depresja	Depresja	Neutrofile
14	Uzależnienie od substancji	Schyłkowa niewydolność nerek (dializa)	Zwłóknienie i inne schorzenia
15	Zapalenie płuc	Psychoterapia	Glukoza
16	Schyłkowa niewydolność nerek (dializa)	Niedożywienie	Hematokryt
17	Azot mocznikowy we krwi (BUN)	Neutrofile	Kreatynina
18	Niedożywienie	Zapalenie płuc	Tętno
19	Psychoterapia	Azot mocznikowy we krwi (BUN)	Wskaźnik masy ciała (BMI)
20	Dodatkowa diagnoza (nie-ICD9)	Zwłóknienie i inne schorzenia	Sód
21	Płęć	Płęć	Płęć
22	Zwłóknienie i inne schorzenia	Dodatkowa diagnoza (nie-ICD9)	Dodatkowa diagnoza (nie-ICD9)

Analiza zawartości tabel potwierdza, że zgodność między technikami jest ograniczona, choć występują powtarzalne wzorce dla wybranych cech. W przypadku modelu 256-256 (*relu*) jedynie dwie cechy (*Skład dochodu z zasobów* oraz *HIV/AIDS*) zostały przypisane do tych samych pozycji (odpowiednio 0 i 2). Dla drugiego zestawu i modelu 64-64-64 (*tanh*) powtórzenie tej samej pozycji wystąpiło dla cech *Liczba wizyt* i *Poważne zaburzenie psychiczne* (pozycje 0 i 1). Chociaż poszczególne metody różnią się w sposobie ustalania dokładnej kolejności, to jednocześnie w większości przypadków ich wyniki są do siebie zbliżone, a różnice dotyczą głównie niewielkich przesunięć pozycji wynikających z minimalnych różnic w wartościach ważności. Analiza wykresów 21a–21b pozwala zauważyć, że w wielu przypadkach o różnicy w pozycji decydują jedynie setne części wartości.

Wyniki wskazują także wysokie podobieństwo pomiędzy technikami PFI i SHAP, które zwracają często podobne profile ważności cech w wielu z testowanych modeli. W celu ilościowego potwierdzenia tej obserwacji przygotowano wykres korelacji rang Spearmana dla obu architektur, przedstawiony na rys. 22. Korelacje pomiędzy tymi metodami wynoszą odpowiednio 0,85 i 0,91, co potwierdza istnienie wyraźnej zależności pomiędzy uzyskiwanymi rankingami. Wysoka zgodność tych dwóch metod wskazuje, że obie techniki w podobny sposób reagują na udział poszczególnych zmiennych

w procesie predykcji. Zgodnie z macierzą ciepła najmniej skorelowana jest metoda **LIME** z pozostałymi technikami w przypadku drugiego zbioru.



Rysunek 22. Korelacja Spearmana rang dla dwóch modeli MLP w postaci macierzy ciepła

4.4 Klasyczne modele

W tej sekcji przedstawiono kontynuację eksperymentów przeprowadzonych dla innych popularnych modeli uczenia maszynowego, stanowiących uzupełnienie analizy wykonanej dla samych sieci neuronowych typu MLP. Celem badań było porównanie skuteczności oraz interpretowalności różnych rodzin modeli — zarówno tych o charakterze czarnoskrzynkowym, jak XGBoost i Random Forest, jak i modeli bardziej przejrzystych, takich jak regresja liniowa. Zatem w eksperymentach wykorzystano cztery modele: najlepszy model MLP wybrany w poprzedniej sekcji, XGBoost, modelu lasu losowego oraz klasycznego modelu regresji liniowej. Uzyskane wyniki umożliwiają porównanie jakości predykcji pomiędzy modelami różniącymi się złożonością, mechanizmem uczenia oraz potencjalnym stopniem interpretowalności.

4.4.1 Skuteczność modeli



Na rys. 23a i 23b przedstawiono wyniki błędów RMSE, MAE oraz współczynnika determinacji R^2 dla zbioru testowego obu zestawów danych. Dodatkowo w tabelach 6a i 6b zestawiono dokładne wartości uzyskanych metryk. Rezultaty wskazują, że najlepszą skuteczność osiągnęły modele Random Forest dla pierwszego zestawu i MLP dla drugiego. Charakteryzują się najniższymi wartościami błędów RMSE i MAE oraz najwyższym współczynnikiem determinacji R^2 . Las losowy uzyskał dla zbioru testowego odpowiednio:

$$\text{RMSE} = 0,643743, \quad \text{MAE} = 0,405079, \quad R^2 = 0,994741.$$

Nieco słabsze, choć wciąż bardzo dobre wyniki, mają modele XGBoost i MLP. Najsłabsze rezultaty zanotowano dla regresji liniowej, która mimo prostoty konstrukcji pozwoliła uzyskać przyzwoite wartości metryk, nie wykluczając jej z dalszej analizy w kontekście interpretowalności cech. W przypadku drugiego zestawu danych również wszystkie modele osiągnęły błędy pozwalają na dalsze rozpatrywanie ich w perspektywie praktycznego zastosowania. Najniższe błędy posiada model MLP wynoszące odpowiednio w zbiorze testowym:

$$\text{RMSE} = 0,516482, \quad \text{MAE} = 0,362663, \quad R^2 = 0,951386.$$

Niewiele gorsze rezultaty osiągnął regresor XGBoost i Random Forest. Ostatecznie wyniki potwierdzają, że złożone modele zespołowe i nieliniowe lepiej odwzorowują zależności w danych.

(a) Zestaw *Life Expectancy*(b) Zestaw *Hospital Length of Stay***Rysunek 23.** Porównanie metryk testowych modeli UM dla dwóch zestawów danych**Tabela 6.** Porównanie dokładnych błędów testowych modeli MLP dla dwóch zestawów danych(a) Zestaw *Life Expectancy*


Model	RMSE	MAE	R ²
Random Forest	0,643743	0,405079	0,994741
XGBoost	1,147293	0,653079	0,983295
MLP	2,287939	1,612449	0,933568
Linear Regression	3,612029	2,790459	0,834427

(b) Zestaw *Hospital Length of Stay*


Model	RMSE	MAE	R ²
MLP	0,516482	0,362663	0,951386
XGBoost	0,605362	0,464907	0,933215
Random Forest	0,627252	0,379295	0,928298
Linear Regression	1,166065	0,891120	0,752203

4.4.2 Techniki XAI


W niniejszej podsekcji przedstawiono wyniki analiz ważności cech uzyskane przy zastosowaniu technik XAI dla wprowadzonych powyżej modeli. Eksperyment przeprowadzono z wykorzystaniem tego samego środowiska obliczeniowego i metodyki, co w przypadku badania różnych architektur MLP. Ponownie celem było porównanie, jak wybór modelu wpływa na rozkład ważności cech i wzajemną zgodność wyników uzyskanych przy użyciu odmiennych technik wyjaśnialności. Podobnie jak przy wcześniejszej analizie przygotowano sześć wykresów słupkowych (rys. 24–29), oraz sześć wykresów pudełkowych (rys. 30–35), które pozwalają na dokładne zbadanie uzyskanych wyników.




Rysunek 24. Wykres słupkowy ważności cech – technika SHAP i zestaw *Life Expectancy*




Rysunek 25. Wykres słupkowy ważności cech – technika PFI i zestaw *Life Expectancy*




Rysunek 26. Wykres słupkowy ważności cech – technika LIME i zestaw *Life Expectancy*




Rysunek 27. Wykres słupkowy ważności cech – technika SHAP i zestaw *Hospital Length of Stay*




Rysunek 28. Wykres słupkowy ważności cech – technika PFI i zestaw *Hospital Length of Stay*




Rysunek 29. Wykres słupkowy ważności cech – technika LIME i zestaw *Hospital Length of Stay*



Rysunek 30. Wykres pudełkowy ważności cech – technika SHAP i zestaw *Life Expectancy*



Rysunek 31. Wykres pudełkowy ważności cech – technika PFI i zestaw *Life Expectancy*



Rysunek 32. Wykres pudełkowy ważności cech – technika LIME i zestaw *Life Expectancy*

Rozkład ważności per cecha dla metody: SHAP

Rysunek 33. Wykres pudełkowy ważności cech – technika SHAP i zestaw *Hospital Length of Stay*

Rozkład ważności per cecha dla metody: PFI



Rysunek 34. Wykres pudełkowy ważności cech – technika PFI i zestaw *Hospital Length of Stay*



Rysunek 35. Wykres pudełkowy ważności cech – technika LIME i zestaw *Hospital Length of Stay*

Podobnie jak w przypadku badania architektur MLP, uzyskane wyniki pokazują, że rozkład ważności cech silnie zależy od typu zastosowanego modelu. Kolejna analogia występuje w przypadku cech: *Skład dochodu z zasobów*, *HIV/AIDS* oraz *Śmiertelność dorosłych*, które ponownie zostały wskazane jako najbardziej istotne we wszystkich technikach i modelach, osiągając średnią skalowaną ważność powyżej 0,52 dla pierwszego zestawu. Ich kolejność pozostaje niezmienna niezależnie od modelu, co wskazuje na stabilność interpretacji względem różnych mechanizmów predykcyjnych. Warto odnotować również, że cecha *Lata edukacji* uzyskała największą rozpiętość wartości ważności (dla SHAP: 0,06–1,00, PFI: 0,02–1,00, LIME: 0,05–1,00), co potwierdza wysoką wrażliwość interpretacji tej zmiennej na strukturę modelu i techniki wyjaśniania. Drugi zestaw danych również

wykazał podobieństwa do wcześniejszych doświadczeń. Uzyskane ważności cech są zdecydowanie bardziej stabilne, a cechy *Liczba wizyt* i *Poważne zaburzenia psychiczne* powtórnie uplasowały się na dwóch pierwszych pozycjach.

Dalszą część analizy stanowią tabele 7a–7b, przedstawiające rankingi cech uzyskane dla każdej techniki i najlepszego modelu, oraz mapa korelacji Spearmana (rys. 36) obrazująca zgodność rang pomiędzy metodami.

Tabela 7. Porównanie rankingów ważności cech dwóch najlepszych modeli


(a) Zestaw *Life Expectancy*
Model Random Forest

	SHAP	PFI	LIME
0	Skład dochodu z zasobów	Skład dochodu z zasobów	Skład dochodu z zasobów
1	Śmiertelność dorosłych	Śmiertelność dorosłych	HIV/AIDS
2	HIV/AIDS	HIV/AIDS	Śmiertelność dorosłych
3	Niedowaga 1–19 lat	Niedowaga 1–19 lat	Niedowaga 1–19 lat
4	Lata edukacji	Alkohol	Lata edukacji
5	Alkohol	Lata edukacji	Wydatki całkowite
6	Rok	Rok	Alkohol
7	Wydatki całkowite	Zgony niemowląt	BMI
8	BMI	Wydatki całkowite	Zgony niemowląt
9	Zgony niemowląt	BMI	Polio
10	PKB	PKB	Rok
11	Polio	Odra	Błonica
12	Błonica	Kraj	PKB
13	Odra	Populacja	WZW B
14	Kraj	Polio	Populacja
15	WZW B	WZW B	Odra
16	Populacja	Błonica	Kraj
17	Status	Status	Status

(b) Zestaw *Hospital Length of Stay*
Model MLP

	SHAP	PFI	LIME
0	Liczba wizyt	Liczba wizyt	Liczba wizyt
1	Poważne zaburzenie psychiczne	Poważne zaburzenie psychiczne	Poważne zaburzenie psychiczne
2	Hematokryt	Depresja	Poziom hemoglobiny
3	Tętno	Glukoza	Azot mocznikowy we krwi (BUN)
4	Sód	Kreatynina	Niedożywienie
5	Wskaźnik masy ciała (BMI)	Tętno	Niedobór żelaza
6	Kreatynina	Poziom hemoglobiny	Depresja
7	Glukoza	Sód	Zapalenie płuc
8	Częstość oddechów	Wskaźnik masy ciała (BMI)	Uzależnienie od substancji
9	Niedobór żelaza	Częstość oddechów	Astma
10	Uzależnienie od substancji	Hematokryt	Psychoterapia
11	Poziom hemoglobiny	Niedobór żelaza	Schyłkowa niewydolność nerek (dializa)
12	Neutrofile	Uzależnienie od substancji	Zwłóknienie i inne schorzenia
13	Depresja	Psychoterapia	Neutrofile
14	Astma	Astma	Tętno
15	Psychoterapia	Niedożywienie	Kreatynina
16	Zapalenie płuc	Schyłkowa niewydolność nerek (dializa)	Płec
17	Azot mocznikowy we krwi (BUN)	Azot mocznikowy we krwi (BUN)	Częstość oddechów
18	Niedożywienie	Zapalenie płuc	Sód
19	Schyłkowa niewydolność nerek (dializa)	Zwłóknienie i inne schorzenia	Hematokryt
20	Zwłóknienie i inne schorzenia	Neutrofile	Wskaźnik masy ciała (BMI)
21	Dodatkowa diagnoza (nie-ICD9)	Płec	Glukoza
22	Płec	Dodatkowa diagnoza (nie-ICD9)	Dodatkowa diagnoza (nie-ICD9)

Analiza rankingu 7a cech pokazuje niską zgodność pomiędzy technikami – największą w modelu Random Forest, gdzie zgodność dotyczyła trzech pozycji (0, 3 i 17), a w przypadku rankingu 7b tylko dwóch pierwszych pozycji (0 i 1).



Rysunek 36. Korelacja Spearmana rang najlepszych modeli w postaci macierzy ciepła

Wykres korelacji rang Spearmana (rys. 36) potwierdza wysoką zgodność pomiędzy technikami PFI i SHAP, których współczynnik przekracza 0,83 w każdym zestawie. Najmniejszą występującą korelację nadal uzyskał model MLP, którego analiza była już przeprowadzana w badaniu wpływu architektur.

4.5 Wnioski

Na podstawie przeprowadzonych prac można stwierdzić, że zarówno część skupiona na architekturach sieci neuronowych, jak i modelach klasycznych tworzą całościowy obraz praktycznego podejścia do uzyskania ważności cech dla modeli o różnym stopniu interpretowalności. Pierwszym istotnym aspektem jest fakt, że dobrane zbiory danych i regresory pozwoliły na uzyskanie porównywalnie wysokiej jakości predykcji, a tym samym ograniczyły wpływ efektywności modelu na przypisywaną ważność zmiennych opisujących. W przypadku pierwszego zestawu danych (*Life Expectancy*) 15 na 18 wytrenowanych modeli dawało porównywalnie niskie błędy RMSE, MAE, a w przypadku drugiego zbioru (*Hospital Length of Stay*) wszystkie badane architektury MLP uzyskały podobnie zadowalającą efektywność.

Przygotowane w ten sposób modele ujawniły istotny wpływ zarówno architektury modelu, jak i zastosowanej techniki XAI na uzyskaną ważność cech. W przypadku pierwszego zestawu zaobserwowano dużą zmienność rankingów pomiędzy modelami MLP (w szczególności w obrębie cech o średniej istotności, dla których wartości ważności obejmowały nawet cały zakres $[0, 1]$). Niemniej jednak we wszystkich technikach konsekwentnie dominowały dwie cechy (*Skład dochodu z zasobów* oraz *HIV/AIDS*), które zawsze zajmowały jedno z pierwszych pozycji. W przypadku drugiego zestawu zakres przypisywanych ważności dla cech był zdecydowanie mniejszy, a cechy *Liczba wizyt* oraz *Poważne zaburzenia psychiczne* zajmowały pierwsze pozycje, bez znaczących odstępstw pomiędzy

architekturami i technikami. Wpływ na taki stan rzeczy mogą mieć wybrane zestawy danych, korelacja pomiędzy cechami oraz dobrane parametry technik XAI. Pozwala to na sformułowanie postulatu, że analiza istotności cech powinna być przeprowadzona w **odniesieniu do konkretnego modelu**, ponieważ zarówno wewnętrzna budowa sieci neuronowej, jak i wybór konkretnego podejścia predykcyjnego mogą wpływać na uzyskane wyniki. Ten sam zestaw cech opisujących może zostać zaklasyfikowany jako nieistotny w jednym rozwiązaniu, a w drugim podejściu stanowić wiodące informacje do uzyskania predykcji. Jest to jednak w dużym stopniu zależne od postawionego problemu i możliwości modelowania wewnętrznych wzorców, które model jest w stanie uzyskać na podstawie uczącego zbioru danych.

Porównanie technik wyjaśniania wykazało natomiast zauważalną spójność pomiędzy technikami SHAP i PFI, które w wielu przypadkach nadawały cechom bardzo podobne pozycje rankingowe. Korelacja rang Spearmana osiągała w ich przypadku wartości powyżej 0,8, co skłania do zajęcia stanowiska, że obie metody w podobny sposób opisują model dla badanych problemów. Globalny wariant techniki LIME, mimo że często wskazywał te same cechy dominujące, charakteryzował się największą zmiennością, a dynamika jego rankingów była najmniej zgodna z pozostałymi metodami. Jest to prawdopodobnie wynik lokalnego charakteru tego podejścia i przypisywania, szczególnie mniej istotnym cechom, ważności w szerokim zakresie, co w pewnym stopniu podważa zasadność stosowania agregowania wyników w celu uzyskania globalnej interpretacji. Szczególnie widoczne było to w pierwszym zestawie danych, gdzie uśrednione globalnie wartości LIME różniły się znacząco pomiędzy modelami, a ich zakres był często węższy dla cech najważniejszych i bardziej nieregularny dla cech o mniejszej istotności.

Podsumowując, przeprowadzone prace eksperymentalne dowodzą, że techniki XAI dostarczają tylko w ograniczonym stopniu spójnych i interpretowalnych informacji o strukturalnych zależnościach pomiędzy cechami a wynikiem modelu. Największą stabilność i zgodność wyników uzyskano dla metod SHAP i PFI, podczas gdy LIME, choć użyteczny, wykazał najwyższą wrażliwość na zmiany modelu i danych. Jednocześnie wszystkie metody konsekwentnie wskazały niewielki zestaw dominujących cech, co pozwala z odpowiednią pewnością stwierdzić, że ich wpływ na proces predykcji jest zarówno istotny, jak i odporny do określonego stopnia na zmiany architektury oraz rodzaju modelu.

Rozdział 5

Podsumowanie

Celem niniejszej pracy była próba odpowiedzenia na pytania dotyczące zasadności stosowania i charakterystyki wyników wyjaśnialnej sztucznej inteligencji (XAI) na podstawie zbadania właściwości trzech popularnych technik analizujących globalną ważność cech: PFI (Permutation Feature Importance), SHAP (SHapley Additive exPlanations) oraz uśrednionej wersji metody LIME (Local Interpretable Model-Agnostic Explanations). Przeprowadzone badania wykazały, że otrzymane wyniki są silnie zależne od charakterystyki danych oraz zastosowanego modelu, a tym samym ich stosowanie jest ściśle powiązane z konkretnym rozwiązaniem predykcyjnym.

Przeprowadzona analiza stabilności rankingów cech wykazała wysoką zgodność pomiędzy technikami PFI i SHAP z korelacją Spearmana przekraczającą wartość 0,8 dla różnych wariantów modeli i danych. Jest to zgodne z przewidywaniami teoretycznymi, ponieważ PFI mierzy spadek jakości po wyłączeniu danej cechy, zaś SHAP określa jak duży średni wpływ ma każda cecha na wynik modelu. Zatem w warunkach stosunkowo niskiej współliniowości oraz umiarkowanej liczby zależności ich zachowania jest zbliżone. Z perspektywy praktycznej podważa to sensowność stosowania mniej wydajnej obliczeniowo i bardziej złożonej teoretycznie metody SHAP. Tym bardziej, że w sytuacji występowania silnych korelacji pomiędzy cechami opisującymi wszystkie testowane techniki mają tendencję do niezgodnego przypisywania ważności cech z rzeczywistym działaniem modelu. W literaturze proponowane są rozszerzone warianty metod dostosowane do danych skorelowanych (np. *conditional SHAP*, *conditional PFI*), które pomagają ograniczyć opisany problem. Niemniej jednak warto podkreślić, że nie istnieje próg współliniowości implikujący konieczność stosowania takich wariantów, więc często pozostaje to do indywidualnej oceny.

Największą rozbieżnością charakteryzował się wariant globalny metody LIME. W znaczącej liczbie przypadków identyfikowała te same cechy dominujące, ale jej rankingi były mniej stabilne, a zakresy znacząco bardziej zróżnicowane. W świetle przeprowadzonych eksperymentów zasadność takiego podejścia jest podważona przez stabilniejsze wyniki pozostałych metod, ale warto podkreślić, że LIME może dostarczyć cennych danych o lokalnych właściwościach, a globalna interpretacja może pełnić rolę wstępnego badania, która wymaga innych technik w celu weryfikacji.

Sama istność cech jest narzędziem użytecznym, ale wymagającym umiejętnej interpretacji. Techniki XAI wykazują się największą stabilnością w identyfikacji niewielkiego zestawu najważniejszych predyktorów, natomiast dalsze pozycje rankingów uzyskują większą zmienność. Oznacza to, że takie techniki mogą służyć jako wskaźnik kluczowych zmiennych, ale nie dają pełnego obrazu całej struktury zależności, a ich wyniki nie są podstawą wniosków przyczynowych. Główna ich wartość wynika z ukierunkowania analizy i wstępnego wskazania najważniejszych aspektów wpływających na wynik, co w wielu przypadkach może być wystarczające.

Przeprowadzone doświadczenia praktyczne pozwalają sformułować odpowiedzi na postawione pytania dotyczące jakości, stabilności oraz spójności ważności cech modeli uczenia maszynowego uzyskanych z pośrednictwem przytoczonych narzędzi. W świetle uzyskanych wyników techniki XAI stanowią wartościowe, choć niepozbawione ograniczeń, narzędzie wspierające zrozumienie modeli. Najbardziej wiarygodne rezultaty zapewnia połączenie PFI i SHAP, przy czym PFI, jako metoda prostsza i często dająca wyniki zbieżne z SHAP, okazuje się szczególnie praktyczna, o ile nie występuje silna współliniowość cech. Żadna z metod nie jest jednak w pełni odporna na ograniczenia wynikające ze struktury danych, co pozostaje kluczowym obszarem ich dalszego rozwoju i odpowiedzialnego stosowania w rzeczywistych systemach. Dalsze prace mogłyby obejmować warianty technik przeznaczonych dla danych skorelowanych lub nowszych technik wyjaśniania (Integrated Gradients, Grad-CAM, Anchors) nawet bez możliwości ich bezpośredniego porównania. Warto byłoby pochylić się również nad aspektem stabilności wyników na syntetycznych zbiorach o kontrolowanej korelacji wykorzystując znajomość teorii stojącej za działaniem każdego podejścia.

Bibliografia

- [1] Ailyn, D., „Explainability and Interpretability in Deep Learning Models”, wrz. 2024.
- [2] Alnusif, M., „Explainable AI in Edge Devices: A Lightweight Framework for Real-Time Decision Transparency”, *International Journal of Engineering and Computer Science*, t. 14, lip. 2025.
- [3] Alves, P., Delgado, J., Gonzalez, L., Rocha, A. R., Boccato, L. i Borin, E., „Comparing LIME and SHAP Global Explanations for Human Activity Recognition”, Springer-Verlag, 2025.
- [4] Aysel, H. I., Cai, X. i Prugel-Bennett, A., „Explainable Artificial Intelligence: Advancements and Limitations”, *Applied Sciences*, 2025.
- [5] Barredo Arrieta, A. i in., „Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI”, *Information Fusion*, s. 82–115, 2020.
- [6] Breiman, L., „Random Forests”, *Machine Learning*, paź. 2001.
- [7] Conard, A. M., DenAdel, A. i Crawford, L., „A spectrum of explainable and interpretable machine learning approaches for genomic studies”, *WIREs Comput. Stat.*, wrz. 2023.
- [8] Dormann, C. i in., „Collinearity: a review of methods to deal with it and a simulation study evaluating their performance”, *Ecography*, sty. 2012.
- [9] El Shawi, R., Sherif, Y., Al-Mallah, M. i Sakr, S., „Interpretability in healthcare: A comparative study of local machine learning interpretability techniques”, *Computational Intelligence*, list. 2020.
- [10] Fisher, A., Rudin, C. i Dominici, F., *All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously*, 2019.
- [11] Guidotti, R., Monreale, A., Ruggieri, S., Turini, F., Pedreschi, D. i Giannotti, F., *A Survey Of Methods For Explaining Black Box Models*, 2018.
- [12] Hettikankanamage, N., Shafiabady, N., Chatteur, F., Wu, R. M. X., Ud Din, F. i Zhou, J., „eXplainable Artificial Intelligence (XAI): A Systematic Review for Unveiling the Black Box Models and Their Relevance to Biomedical Imaging and Sensing”, *Sensors*, 2025.
- [13] Khan, A., Ali, A., Khan, J., Ullah, F. i Khan, M., „A Systematic Literature Review of Explainable Artificial Intelligence (XAI) in Software Engineering (SE)”, 2023.
- [14] Kumar, I. E., Venkatasubramanian, S., Scheidegger, C. i Friedler, S., *Problems with Shapley-value-based explanations as feature importance measures*, 2020.

- [15] Linardatos, P., Papastefanopoulos, V. i Kotsiantis, S., „Explainable AI: A Review of Machine Learning Interpretability Methods”, *Entropy*, 2021.
- [16] Linden, I. van der, Haned, H. i Kanoulas, E., *Global Aggregations of Local Explanations for Black Box models*, 2019.
- [17] Lundberg, S. M. i Lee, S.-I., „A unified approach to interpreting model predictions”, 2017.
- [18] Mersha, M., Lam, K., Wood, J., AlShami, A. K. i Kalita, J., „Explainable artificial intelligence: A survey of needs, techniques, applications, and future direction”, *Neurocomputing*, 2024.
- [19] Michalski, R. S., „A theory and methodology of inductive learning”, *Artificial Intelligence*, nr. 2, 1983.
- [20] Mittelstadt, B., Russell, C. i Wachter, S., „Explaining Explanations in AI”, w *Proceedings of the Conference on Fairness, Accountability, and Transparency*, ACM, 2019.
- [21] Montavon, G., Samek, W. i Müller, K.-R., „Methods for interpreting and understanding deep neural networks”, *Digital Signal Processing*, lut. 2018.
- [22] Nestor, M. i al., et, *Artificial Intelligence Index Report 2025*, 2025.
- [23] P M, A., Luo, X., Liu, Q., Madarkar, R. i Walker, C., „Towards next-gen smart manufacturing systems: the explainability revolution”, *npj Advanced Manufacturing*, list. 2024.
- [24] Ribeiro, M. T., Singh, S. i Guestrin, C., „Why Should I Trust You?": *Explaining the Predictions of Any Classifier*, 2016.
- [25] Ridley, M., „Explainable Artificial Intelligence (XAI)”, *Information Technology and Libraries*, czer. 2022.
- [26] Rudin, C., *Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead*, 2018.
- [27] Silva, S. J. i Keller, C. A., „Limitations of XAI Methods for Process-Level Understanding in the Atmospheric Sciences”, *Artificial Intelligence for the Earth Systems*, 2024.
- [28] *TechDispatch – Explainable artificial intelligence*. Publications Office of the European Union, 2023.
- [29] Vilone, G. i Luca, L., „Classification of Explainable Artificial Intelligence Methods through Their Output Formats”, *Mach. Learn. Knowl. Extr.*, 2021.
- [30] Wiratsin, I.-O. i Ragkhitwetsagul, C., „Effectiveness of Explainable Artificial Intelligence (XAI) Techniques for Improving Human Trust in Machine Learning Models: A Systematic Literature Review”, *IEEE Access*, 2025.

Wykaz skrótów i symboli

ISEP Instytut Sterowania i Elektroniki Przemysłowej 1

LIME Local Interpretable Model-agnostic Explanations 3, 5, 11, 20–22, 33, 34, 36, 43, 46, 48, 51, 52, 61, 64, 66, 69, 72, 73, 79, 80

MLP Multilayer Perceptrons 20, 33, 34, 38, 40, 56–58, 69–71, 81

OECD Organisation for Economic Co-operation and Development 11

ONZ Organizacja Narodów Zjednoczonych 11

PFI Permutation Feature Importance 3, 5, 11, 25, 33, 34, 36, 42, 45, 47, 50–52, 60, 63, 65, 68, 69, 71–74, 79, 80

RODO Ogólne Rozporządzenie o Ochronie Danych Osobowych 11

SHAP Shapley Additive Explanations 3, 5, 11, 22–24, 33, 34, 36, 41, 44, 47, 49, 51, 52, 59, 62, 65, 67, 69, 71–74, 79, 80

SI Sztuczna Inteligencja 9–11, 14, 79

UM Uczenie Maszynowe 9, 13, 22, 33, 57, 79

XAI Explainable AI 3, 5, 7, 11–17, 19, 25, 27, 29, 31, 33, 34, 37, 40, 52, 58, 71–74, 81

Spis rysunków

1	Wykorzystanie SI w funkcjach biznesowych w latach 2017–2024, źródło: [22]	10
2	Liczba publikacji o SI w dziedzinie informatyki na świecie w latach 2013–2023, źródło: [22]	10
3	Spektrum przejrzystości modeli uczenia maszynowego, źródło: <i>opracowanie własne</i> .	16
4	Wyniki analizy istotności cech uzyskane metodą LIME dla obserwacji, źródło: <i>opracowanie własne</i>	21
5	Wyniki analizy istotności cech uzyskane metodą SHAP dla zbioru, źródło: <i>opracowanie własne</i>	24
6	Macierz korelacji cech — zbiór <i>Life Expectancy (WHO)</i>	29
7	Macierz korelacji cech — zbiór <i>Hospital Length of Stay (Microsoft)</i>	31
8	Porównanie metryk testowych modeli MLP dla dwóch zestawów danych	39
9	Wykres słupkowy ważności cech — technika SHAP i zestaw <i>Life Expectancy</i>	41
10	Wykres słupkowy ważności cech — technika PFI i zestaw <i>Life Expectancy</i>	42
11	Wykres słupkowy ważności cech — technika LIME i zestaw <i>Life Expectancy</i>	43
12	Wykres słupkowy ważności cech — technika SHAP i zestaw <i>Hospital Length of Stay</i> .	44
13	Wykres słupkowy ważności cech — technika PFI i zestaw <i>Hospital Length of Stay</i> .	45
14	Wykres słupkowy ważności cech — technika LIME i zestaw <i>Hospital Length of Stay</i> .	46
15	Wykres pudełkowy ważności cech — technika SHAP i zestaw <i>Life Expectancy</i>	47
16	Wykres pudełkowy ważności cech — technika PFI i zestaw <i>Life Expectancy</i>	47
17	Wykres pudełkowy ważności cech — technika LIME i zestaw <i>Life Expectancy</i>	48
18	Wykres pudełkowy ważności cech — technika SHAP i zestaw <i>Hospital Length of Stay</i> .	49
19	Wykres pudełkowy ważności cech — technika PFI i zestaw <i>Hospital Length of Stay</i> .	50
20	Wykres pudełkowy ważności cech — technika LIME i zestaw <i>Hospital Length of Stay</i> .	51
21	Porównanie ważności cech dla dwóch najlepszych modeli MLP	53
22	Korelacja Spearmana rang dla dwóch modeli MLP w postaci macierzy ciepła	55
23	Porównanie metryk testowych modeli UM dla dwóch zestawów danych	57
24	Wykres słupkowy ważności cech — technika SHAP i zestaw <i>Life Expectancy</i>	59
25	Wykres słupkowy ważności cech — technika PFI i zestaw <i>Life Expectancy</i>	60

26	Wykres słupkowy ważności cech – technika LIME i zestaw <i>Life Expectancy</i>	61
27	Wykres słupkowy ważności cech – technika SHAP i zestaw <i>Hospital Length of Stay</i> .	62
28	Wykres słupkowy ważności cech – technika PFI i zestaw <i>Hospital Length of Stay</i> . .	63
29	Wykres słupkowy ważności cech – technika LIME i zestaw <i>Hospital Length of Stay</i> .	64
30	Wykres pudełkowy ważności cech – technika SHAP i zestaw <i>Life Expectancy</i>	65
31	Wykres pudełkowy ważności cech – technika PFI i zestaw <i>Life Expectancy</i>	65
32	Wykres pudełkowy ważności cech – technika LIME i zestaw <i>Life Expectancy</i>	66
33	Wykres pudełkowy ważności cech – technika SHAP i zestaw <i>Hospital Length of Stay</i>	67
34	Wykres pudełkowy ważności cech – technika PFI i zestaw <i>Hospital Length of Stay</i> .	68
35	Wykres pudełkowy ważności cech – technika LIME i zestaw <i>Hospital Length of Stay</i>	69
36	Korelacja Spearmana rang najlepszych modeli w postaci macierzy ciepła	71

Spis tabel

1	Zbiór <i>Life Expectancy (WHO)</i> — wybrane cechy i ich opis.	28
2	Zbiór <i>Hospital Length of Stay</i> — wybrane cechy i ich opis	30
3	Zestawienie bibliotek kluczowych dla warstwy modeli i XAI	37
4	Porównanie dokładnych błędów testowych modeli MLP dla dwóch zestawów danych	40
5	Porównanie rankingów ważności cech dla dwóch modeli MLP	54
6	Porównanie dokładnych błędów testowych modeli MLP dla dwóch zestawów danych	57
7	Porównanie rankingów ważności cech dwóch najlepszych modeli	70